PROPOSAL PENELITIAN

ANALISIS PERFORMA DAN AKURASI MODEL WHISPER PADA SISTEM TRANSKRIPSI TERDISTRIBUSI MENGGUNAKAN NEXT.JS DAN PYTHON WORKER

UIN IMAM BONJOL
PADANG

Oleh:

MUHAMAD IFFAN RAMADHAN

NIM. 2117020036

PROGRAM STUDI SISTEM INFORMASI
FAKULTAS SAINS DAN TEKNOLOGI
UNIVERSITAS ISLAM NEGERI IMAM BONJOL PADANG

2026

PROPOSAL PENELITIAN

ANALISIS PERFORMA DAN AKURASI MODEL WHISPER PADA SISTEM TRANSKRIPSI TERDISTRIBUSI MENGGUNAKAN NEXT.JS DAN PYTHON WORKER

Diajukan Sebagai Salah Satu Syarat untuk Meraih Gelar Sarjana (S1)

UIN IMAM BONJOL
PADANG

Oleh:

MUHAMAD IFFAN RAMADHAN
NIM. 2117020036

PROGRAM STUDI SISTEM INFORMASI
FAKULTAS SAINS DAN TEKNOLOGI
UNIVERSITAS ISLAM NEGERI IMAM BONJOL PADANG

2026

HALAMAN PERSETUJUAN

Proposal penelitian dengan judul **"Analisis Performa dan Akurasi Model Whisper pada Sistem Transkripsi Terdistribusi Menggunakan Next.js dan Python Worker"** yang disusun oleh MUHAMAD IFFAN RAMADHAN NIM 2117020036, telah diperiksa dan disetujui untuk diajukan dalam seminar proposal pada Program Studi Sistem Informasi Fakultas Sains dan Teknologi Universitas Islam Negeri Imam Bonjol Padang.

Padang, ... 2026

Menyetujui:

Pembimbing I	Pembimbing II
Ahmad Fauzi, M.T.I	**Ozzy Secio Riza, M.Kom**
NIP. 123456789	NIP. 987654321

KATA PENGANTAR

Puji syukur penulis panjatkan ke hadirat Allah SWT atas segala rahmat dan karunia-Nya sehingga proposal penelitian yang berjudul "Analisis Performa dan Akurasi Model Whisper pada Sistem Transkripsi Terdistribusi Menggunakan Next.js dan Python Worker" ini dapat diselesaikan. Shalawat serta salam semoga senantiasa tercurah kepada Nabi Muhammad SAW sebagai uswatun hasanah bagi umat manusia.

Proposal penelitian ini disusun sebagai salah satu syarat untuk melaksanakan penelitian skripsi pada Program Studi Sistem Informasi, Fakultas Sains dan Teknologi, Universitas Islam Negeri Imam Bonjol Padang. Penulis menyadari bahwa penyelesaian proposal ini tidak lepas dari bimbingan, dukungan, dan bantuan dari berbagai pihak. Oleh karena itu, penulis menyampaikan ucapan terima kasih kepada Bapak Ahmad Fauzi, M.T.I selaku Pembimbing I dan Ibu Ozzy Secio Riza, M.Kom selaku Pembimbing II yang telah memberikan arahan dan masukan yang sangat berharga.

Penulis menyadari bahwa proposal ini masih jauh dari kesempurnaan. Oleh karena itu, kritik dan saran yang membangun sangat penulis harapkan demi perbaikan di masa yang akan datang. Akhir kata, semoga proposal penelitian ini dapat memberikan manfaat bagi pengembangan ilmu pengetahuan, khususnya di bidang teknologi informasi.

Padang, ... 2026

Penulis

DAFTAR ISI

HALAMAN PERSETUJUAN ..... **iii**

KATA PENGANTAR ..... **iv**

DAFTAR ISI ..... **v**

DAFTAR TABEL ..... **vi**

DAFTAR GAMBAR ..... **vii**

BAB I PENDAHULUAN **1**

A Latar Belakang 1

B Rumusan Masalah 3

C Batasan Masalah 3

D Tujuan Penelitian 3

E Manfaat Penelitian 4

BAB II TINJAUAN PUSTAKA **5**

A Kerangka Teori 5

B Literatur Review 7

BAB IIIMETODE PENELITIAN **13**

A Metode Penelitian 13

B Tempat Penelitian 13

C Prosedur Penelitian 13

D Data dan Sumber Data 15

E Alat dan Instrumen Penelitian 16

F Jadwal Penelitian 17

DAFTAR PUSTAKA **18**

DAFTAR TABEL

2.1 Ringkasan Literatur Review 8

3.1 Statistik Dataset Penelitian 16

3.2 Jadwal Penelitian (*Gantt Chart*) 17

DAFTAR GAMBAR

3.1 Alur Penelitian (*Flowchart*)..... 15

BAB I
PENDAHULUAN

A. Latar Belakang

Proses mengubah data suara menjadi teks (*transkripsi*) merupakan tahapan yang krusial namun seringkali menjadi beban kerja terberat dalam dokumentasi informasi, terutama pada konten berdurasi panjang seperti siniar (*podcast*) atau rekaman wawancara penelitian. Meskipun data audio sangat kaya akan informasi, keterbatasannya dalam hal pencarian kata kunci dan aksesibilitas membuat transkripsi teks menjadi kebutuhan yang mendesak bagi para peneliti, jurnalis, dan institusi pendidikan (Imai, Chowdhury, and Stent, 2025). Masalah utamanya adalah transkripsi manual memerlukan konsentrasi tinggi dan waktu yang sangat lama, di mana seorang transkriptor profesional sekalipun biasanya membutuhkan waktu hingga lima jam hanya untuk menyelesaikan satu jam rekaman audio (Christodoulidou , dkk., 2025). Di berbagai instansi dan lembaga pendidikan, keterbatasan waktu ini seringkali menyebabkan banyak data audio berharga berakhir menjadi tumpukan berkas digital yang sulit dimanfaatkan secara optimal.

Perkembangan teknologi *Automatic Speech Recognition* (ASR) berbasis *Transformer*, seperti model *Whisper* yang dikembangkan oleh OpenAI, menawarkan potensi besar untuk memangkas waktu kerja tersebut melalui otomatisasi. Dengan pelatihan menggunakan 680.000 jam data audio multibahasa, *Whisper* mampu mengenali berbagai dialek dan istilah teknis dengan tingkat akurasi yang melampaui generasi model ASR sebelumnya (Radford , dkk., 2022). Namun, efektivitas model ini pada data percakapan alami bahasa Indonesia masih menghadapi tantangan berupa ambiguitas linguistik, gangguan latar belakang, dan penggunaan bahasa gaul yang sering muncul dalam siniar. Oleh karena itu, hasil transkripsi otomatis belum dapat dianggap sebagai produk akhir yang sempurna dan tetap membutuhkan proses penyuntingan manual untuk menjamin kualitasnya. Penelitian sebelumnya menunjukkan bahwa alur kerja yang menggabungkan draf otomatis dengan antarmuka koreksi manusia (*human-in-the-loop*) dapat meningkatkan produktivitas

secara signifikan jika dikelola melalui sistem yang efisien (Olev and Alumäe, 2022).

Tantangan berikutnya muncul dari sisi infrastruktur, di mana penggunaan layanan ASR berbasis *cloud* komersial seringkali terbentur pada masalah biaya yang mahal dan kekhawatiran terkait keamanan data sensitif (Ferraro, Galli, La Gatta, and Postiglione, 2023). Bagi institusi lokal, mengirimkan data audio internal ke server pihak ketiga di luar negeri bukan hanya membebani anggaran, tetapi juga berisiko terhadap privasi informasi yang terkandung di dalamnya. Pemanfaatan perangkat keras internal dengan spesifikasi *Graphic Processing Unit* (GPU) mumpuni yang sudah tersedia di berbagai komputer atau laptop operasional instansi dapat menjadi solusi alternatif yang lebih aman dan berkelanjutan untuk menjalankan model AI secara mandiri (*self-hosted*). Akan tetapi, pengoperasian model AI skala besar secara lokal membutuhkan sistem manajemen tugas yang kokoh agar sumber daya komputasi dapat digunakan secara optimal tanpa mengganggu kinerja aplikasi bagi pengguna. Kemandirian teknologi dalam pengolahan data bahasa ini menjadi sangat penting untuk memastikan keberlanjutan operasional sistem di masa depan (Fathony, Mareta, Adiana, Wardhani, and Halim, 2025).

Sistem Skriptor hadir sebagai solusi untuk menjembatani kesenjangan antara kecanggihan model AI dengan kebutuhan praktis pengguna di lapangan. Skriptor dirancang sebagai platform transkripsi mandiri yang menggunakan arsitektur terdistribusi dengan memisahkan antarmuka pengguna berbasis *Next.js* dari unit pemrosesan AI berbasis *Python Worker*. Pendekatan ini memungkinkan sistem untuk tetap responsif dan stabil meskipun sedang menangani beban kerja inferensi yang berat pada berkas audio berdurasi panjang. Melalui arsitektur ini, pengguna dapat melakukan koreksi teks secara interaktif sementara sistem terus memproses antrean audio lainnya di latar belakang secara asinkron. Penelitian ini akan berfokus pada analisis mendalam mengenai performa berbagai varian model *Whisper* serta efektivitas rancang bangun sistem Skriptor dalam mendukung efisiensi transkripsi data siniar bahasa Indonesia.

B. Rumusan Masalah

Berdasarkan latar belakang di atas, rumusan masalah dalam penelitian ini adalah:

1. Bagaimana perbandingan performa kecepatan (*inference time*) dan efisiensi penggunaan VRAM antar varian model *Whisper* pada sistem terdistribusi?
2. Sejauh mana tingkat akurasi (*Word Error Rate* dan *Character Error Rate*) yang dihasilkan oleh berbagai varian model *Whisper* pada data siniar bahasa Indonesia?
3. Bagaimana rancang bangun sistem transkripsi terdistribusi menggunakan *Next.js* dan *Python Worker* dapat mendukung efisiensi alur kerja koreksi transkrip secara manual?

C. Batasan Masalah

Penelitian ini dibatasi pada hal-hal sebagai berikut:

1. Model yang diuji terbatas pada varian *Whisper* (*Tiny, Small, Medium, Large-v3, Large-v3-Turbo*).
2. Sistem dibangun menggunakan framework *Next.js* 16 dengan dukungan *TypeScript* dan arsitektur *distributed task queue* berbasis *Redis* untuk menjamin skalabilitas.
3. Dataset yang digunakan berasal dari korpus *Mozilla Common Voice* (Siniar *Homostoria* dan *Hari Minggoean*) dalam bahasa Indonesia.
4. Infrastruktur pengujian menggunakan spesifikasi NVIDIA RTX A5000 pada lingkungan *Runpod*.

D. Tujuan Penelitian

Tujuan dari penelitian ini adalah:

1. Menganalisis perbandingan performa kecepatan dan konsumsi sumber daya dari seluruh varian model *Whisper* untuk menentukan efisiensi operasional.
2. Mengukur tingkat akurasi (WER dan CER) model *Whisper* pada dataset bahasa Indonesia untuk mengidentifikasi varian yang paling reliabel.
3. Merancang dan membangun arsitektur sistem transkripsi terdistribusi yang

mencakup antarmuka penyuntingan interaktif untuk memudahkan koreksi hasil AI.

E. Manfaat Penelitian

Manfaat yang diharapkan dari penelitian ini adalah:

1. **Manfaat Teoritis:** Memberikan data *benchmarking* terbaru mengenai performa model ASR *Transformer* pada bahasa Indonesia serta kontribusi pada literatur rancang bangun sistem AI terdistribusi. Penelitian ini juga memperkaya kajian mengenai interaksi manusia dan komputer dalam proses koreksi data hasil otomatisasi.
2. **Manfaat Praktis:** Menyediakan solusi sistem transkripsi mandiri (*self-hosted*) bernama Skriptor yang ekonomis bagi institusi akademis dan profesional. Sistem ini membantu mengurangi biaya operasional, meningkatkan keamanan privasi data, dan mempercepat alur kerja pembuatan transkrip melalui fitur penyuntingan yang terintegrasi.

BAB II
TINJAUAN PUSTAKA

A. Kerangka Teori

Bagian ini memaparkan teori-teori dasar yang menjadi landasan dalam pengembangan dan analisis sistem transkripsi terdistribusi.

1. Automatic Speech Recognition (ASR)

Automatic Speech Recognition (ASR) adalah teknologi yang memungkinkan komputer untuk mengubah sinyal suara menjadi teks secara otomatis. Proses ini melibatkan konversi gelombang akustik mentah menjadi representasi digital yang kemudian dipetakan ke dalam satuan bahasa (fonem, suku kata, atau kata). Secara tradisional, sistem ASR mengandalkan komponen terpisah seperti model akustik, model bahasa, dan leksikon pelafalan. Namun, perkembangan terkini telah bergeser ke arah model *End-to-End* (E2E) yang menyederhanakan alur kerja tersebut menjadi satu jaringan saraf tunggal yang melakukan pemetaan langsung dari audio ke teks (Prabhavalkar, Hori, Sainath, Schlüter, and Watanabe, 2023).

2. Arsitektur Model Whisper

Whisper merupakan sistem ASR *state-of-the-art* yang dikembangkan oleh OpenAI menggunakan arsitektur *Transformer* berbasis *encoder-decoder*.

1. **Arsitektur Encoder-Decoder:** *Encoder* bertugas mengekstraksi fitur dari spektrogram audio, sementara *decoder* memprediksi urutan teks secara autoregresif berdasarkan representasi dari *encoder* dan token teks sebelumnya (Latif , dkk., 2025).
2. **Varian Model:** Whisper tersedia dalam berbagai ukuran, mulai dari *tiny* (39M parameter) hingga *large-v3* (1550M parameter). Varian terbaru, *large-v3-turbo*, dioptimasi untuk kecepatan tanpa mengorbankan akurasi secara signifikan (Andreyev, 2025).
3. **Weakly Supervised Training:** Model ini dilatih menggunakan 680.000 jam

data audio yang dikumpulkan dari internet dengan label transkripsi yang tidak dikurasi secara ketat (*weakly supervised*), sehingga menghasilkan tingkat ketahanan (*robustness*) yang tinggi terhadap aksen dan kebisingan (Radford , dkk., 2022).

3. Optimasi Inferensi: Faster-Whisper dan Kuantisasi

Untuk menjalankan model besar pada lingkungan produksi yang efisien, diperlukan teknik optimasi inferensi.

1. **CTranslate2:** Pustaka yang mengimplementasikan inferensi model *Transformer* secara efisien melalui teknik *fusion* operator dan manajemen memori yang ketat.
2. **Kuantisasi Model:** Proses pengurangan presisi numerik bobot model (misalnya dari FP16 ke INT8). Teknik ini secara signifikan mereduksi penggunaan VRAM dan mempercepat waktu eksekusi dengan degradasi akurasi yang minimal (Andreyev, 2025).
3. **Real Time Factor (RTF):** Metrik utama yang mengukur kecepatan inferensi dengan membandingkan waktu pemrosesan terhadap durasi audio asli. RTF $<$ 1 menunjukkan sistem mampu memproses audio lebih cepat dari waktu nyata.

4. Metrik Evaluasi: WER dan CER

Akurasi sistem ASR diukur menggunakan metrik berbasis *Levenshtein Distance*.

1. **Word Error Rate (WER):** Menghitung rasio kesalahan pada tingkat kata (substitusi, penghapusan, penyisipan) terhadap total kata referensi (Ferraro , dkk., 2023).
2. **Character Error Rate (CER):** Serupa dengan WER namun diterapkan pada tingkat karakter, yang sangat berguna untuk mengevaluasi ketelitian ejaan pada bahasa dengan morfologi kompleks.

5. Arsitektur Sistem Terdistribusi

Sistem skala besar memerlukan pemisahan beban kerja melalui arsitektur terdistribusi.

1. **Message Queue Pattern:** Pola arsitektur di mana produsen tugas (*producer*) memasukkan pekerjaan ke dalam antrean (*queue*) yang kemudian diambil oleh unit pemrosesan (*worker*) secara asinkron.
2. **Worker Pattern:** Memungkinkan skalabilitas horizontal di mana beberapa unit pemrosesan dapat berjalan secara paralel untuk menangani antrean tugas yang intensif komputasi (Macháček, Dabre, and Bojar, 2023).

6. Human-in-the-Loop (HITL) dan Koreksi Manual

Konsep *Human-in-the-loop* (HITL) mengakui keterbatasan AI dan menempatkan manusia sebagai validator akhir. Implementasi antarmuka yang intuitif dengan visualisasi bentuk gelombang audio yang tersinkronisasi sangat penting untuk efisiensi proses koreksi manual (Imai , dkk.; Olev and Alumäe, 2025; 2022).

7. Karakteristik Bahasa Indonesia untuk ASR

Bahasa Indonesia memiliki tantangan tersendiri dalam ASR karena variasi dialek dan statusnya yang sering dikategorikan sebagai *low-resource language* dalam beberapa korpus besar. Meskipun Whisper memiliki performa multibahasa yang baik, akurasinya pada bahasa Indonesia sering kali lebih rendah dibandingkan bahasa Inggris, sehingga memerlukan evaluasi spesifik menggunakan dataset lokal (Fathony , dkk., 2025).

B. Literatur Review

Tinjauan pustaka dilakukan dengan menganalisis berbagai penelitian terdahulu yang memiliki relevansi dengan pemrosesan bahasa alami dan arsitektur sistem terdistribusi. Data literatur tersebut dirangkum dalam Tabel 2.1 untuk memberikan gambaran komprehensif mengenai metode, tujuan, dan temuan utama dari setiap penelitian yang dirujuk.

Tabel 2.1: Ringkasan Literatur Review

Judul	**Penulis**	**Metode Penelitian**	**Tujuan Penelitian**	**Hasil Penelitian**
User-centered Design Methods in Data-Intensive Software...	Riebel (2023)	Literature Review	Menganalisis integrasi UCD dalam AI	UCD meningkatkan empati dan definisi masalah dalam pengembangan AI.
Benchmarking open source and paid services for speech to text...	Ferraro , dkk. (2023)	Benchmark & WER Analysis	Membandingkan performa layanan ASR berbayar dan open-source.	Layanan berbayar lebih akurat, namun performa sangat bergantung pada variasi input teks.
Evaluating Open-Source ASR Systems...	Imai , dkk. (2025)	Evaluasi Eksperimental	Mengukur akurasi ASR pada audio bising	Perlu robust error correction untuk mengatasi bias demografis.
End-to-End Speech Recognition: A Survey	Prabhavalkar , dkk. (2023)	Survey Literatur	Memetakan perkembangan E2E ASR	Model E2E mereduksi WER hingga 50% dibanding HMM tradisional.
Transformers in Speech Processing: A Survey	Latif , dkk. (2025)	Survey Literatur	Menganalisis Transformer dalam audio	Transformer unggul dalam memodelkan dependensi jangka panjang.
Berlanjut ke halaman berikutnya				

Tabel 2.1 – Lanjutan dari halaman sebelumnya

Judul	**Penulis**	**Metode Penelitian**	**Tujuan Penelitian**	**Hasil Penelitian**
Multilingual DistilWhisper...	Ferraz, Boito, Brun, and Nikoulina (2024)	Eksperimental (Distillation)	Meringankan model Whisper untuk bahasa langka	DistilWhisper meningkatkan performa bahasa under-represented dengan overhead minim.
Does ChatGPT and Whisper Make Humanoid Robots More Relatable?	Chen, Luo, Gee, and Nejati (2024)	Evaluasi Pengguna	Membandingkan Whisper vs Google ASR pada robot	Whisper memiliki WER terendah (1.71%) dan paling disukai oleh pengguna.
Quantization for OpenAI's Whisper Models...	Andreyev (2025)	Analisis Komparatif	Mengukur dampak kuantisasi pada latensi	Kuantisasi INT8 mereduksi size 45% dan latensi 19% tanpa degradasi akurasi.
A Self-Training Approach for Whisper to Enhance Long Dysarthric Speech...	Wang, Zhou, Zhao, and Qin (2025)	Self-training method	Meningkatkan ASR untuk penderita disartria	Metode self-training meningkatkan performa pada ucapan penderita disabilitas.
Berlanjut ke halaman berikutnya				

Tabel 2.1 – Lanjutan dari halaman sebelumnya

Judul	**Penulis**	**Metode Penelitian**	**Tujuan Penelitian**	**Hasil Penelitian**
Accurate Speech Recognition AI using Model of Deep Learning...	Isyanto, Ibrahim, Samsinar, and Sudarwati (2024)	Eksperimental CNN	Membangun ASR untuk keamanan perbankan	Algoritma CNN mencapai akurasi 99% untuk pengenalan kata kunci keamanan.
Evaluating OpenAI's Whisper ASR...	Graham and Roll (2024)	Analisis Performa	Mengevaluasi Whisper pada berbagai aksen	Whisper lebih akurat pada aksen asli (native) dibandingkan aksen non-native.
The Role of TypeScript in Enhancing Development...	Emmanni (2021)	Empirical Analysis	Menganalisis peran TypeScript dalam pengembangan aplikasi web modern.	TypeScript secara signifikan mengurangi kesalahan runtime dan meningkatkan skalabilitas.
A Comparative Study of Agile and Waterfall Software Development...	John and Sharma (2024)	Analisis Komparatif	Membandingkan Agile vs Waterfall	Agile lebih unggul dalam kepuasan pelanggan dan kecepatan pengembangan.

Berlanjut ke halaman berikutnya

Tabel 2.1 – Lanjutan dari halaman sebelumnya

Judul	Penulis	Metode Penelitian	Tujuan Penelitian	Hasil Penelitian
Turning Whisper into Real-Time Transcription System	Macháček , dkk. (2023)	Implementasi	Mengembangkan sistem transkripsi real-time berbasis Whisper.	Whisper-Streaming mencapai latensi 3,3 detik dengan akurasi yang tetap terjaga.
WhisperX: Time-Accurate Speech Transcription...	Bain, Huh, Han, and Zisserman (2023)	Pengembangan Sistem	Penyelarasan waktu tingkat kata pada Whisper	VAD dan forced alignment memungkinkan transkripsi 12x lebih cepat.
Bridging the Gap Between Generalized ASR and Domain-Specific...	Nelson and Gretkzi (2023)	Integrasi Vosk	Menyesuaikan ASR untuk domain spesifik	Language modeling pada Vosk efektif untuk istilah medis dan hukum.
A semi-automatic pipeline for transcribing child speech	Christodoulidou , dkk. (2025)	Evaluasi Pipeline	Membangun pipeline transkripsi suara anak	Koreksi manual sebelum forced alignment meningkatkan kualitas data akustik.
Comparing ASR Systems in Context of Speech Disfluencies	Teleki, Dong, Kim, and Caverlee (2024)	Analisis Korpus Besar	Mengevaluasi Google ASR vs Whisper	Whisper lebih unggul dalam menangani interjeksi dan keraguan bicara.

Berlanjut ke halaman berikutnya

Tabel 2.1 – Lanjutan dari halaman sebelumnya

Judul	**Penulis**	**Metode Penelitian**	**Tujuan Penelitian**	**Hasil Penelitian**
Perancangan Antarmuka Pengguna Aplikasi Informasi Siswa...	Pratiwi, Wijoyo, and Wicaksono (2022)	User Centered Design (UCD)	Merancang aplikasi informasi sekolah	Metode UCD menghasilkan desain yang 100% dapat digunakan oleh target user.
Estonian Speech Recognition and Transcription Editing Service	Olev and Alumäe (2022)	Pengembangan Layanan	Membangun sistem transkripsi berbasis wav2vec2.0	Sistem berbasis E2E mencapai WER 6.9% dan mendukung editing kolaboratif.

Berdasarkan tinjauan literatur di atas, penelitian ini memfokuskan diri pada integrasi sistem transkripsi berbasis *Next.js* dan *Python Worker* dalam arsitektur terdistribusi yang dioptimasi untuk penggunaan institusi lokal. Penelitian ini mengisi celah dengan menggabungkan performa model WhisperX yang telah terbukti unggul dengan antarmuka koreksi manual yang dirancang menggunakan prinsip UCD. Melalui pendekatan ini, diharapkan transkripsi bahasa Indonesia pada data siniar dapat dilakukan dengan akurasi yang lebih tinggi dan waktu koreksi yang lebih singkat.

BAB III
METODE PENELITIAN

A. Metode Penelitian

Penelitian ini dikategorikan sebagai penelitian eksperimental teknis dengan fokus pada pengujian performa (*benchmarking*) dan pengembangan sistem (*Research and Development*). Peneliti melakukan eksperimen langsung terhadap berbagai varian model *Whisper* untuk mengukur metrik akurasi dan kecepatan dalam lingkungan sistem terdistribusi. Melalui pendekatan ini, peneliti dapat melakukan kontrol penuh terhadap variabel lingkungan untuk mendapatkan data yang valid dan reliabel. Implementasi sistem secara nyata juga dilakukan untuk memvalidasi bahwa hasil *benchmarking* memiliki relevansi tinggi dalam skenario penggunaan dunia nyata agar dapat memberikan kontribusi praktis yang signifikan.

B. Tempat Penelitian

Penelitian ini dilakukan secara daring melalui pemanfaatan infrastruktur *cloud* dan perangkat keras lokal. Pengujian dilakukan menggunakan *remote pod* dari layanan *Runpod* untuk mendapatkan lingkungan komputasi GPU yang terkontrol menggunakan NVIDIA RTX A5000 dengan kapasitas VRAM sebesar 24GB. Lokasi ini dipilih karena menyediakan fleksibilitas dalam memilih spesifikasi perangkat keras yang sesuai dengan standar kebutuhan model kecerdasan buatan skala besar.

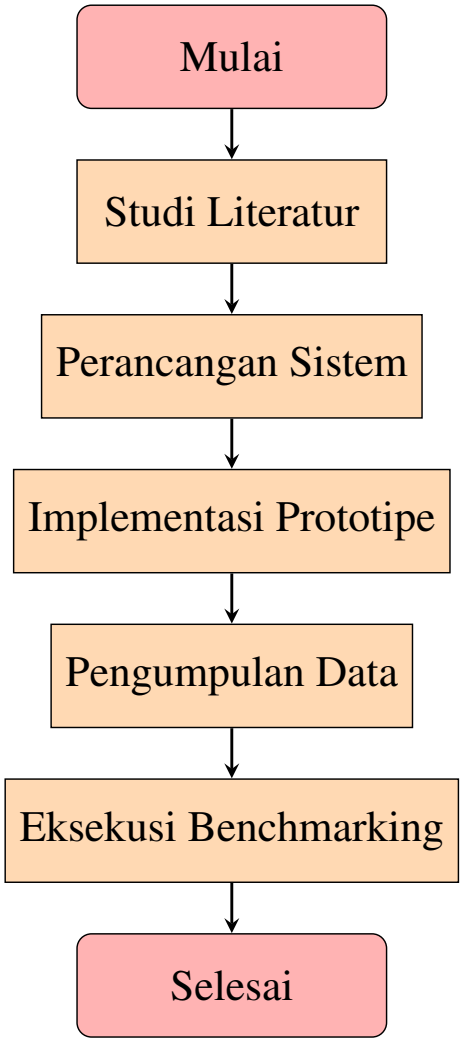
C. Prosedur Penelitian

Prosedur ini dirancang secara sistematis untuk memastikan setiap tahap memiliki luaran yang dapat divalidasi pada tahap berikutnya. Berikut adalah penjabaran rinci dari setiap tahapan penelitian:

1. **Studi Literatur:** Melakukan peninjauan mendalam terhadap dokumentasi model *Whisper*, arsitektur sistem terdistribusi berbasis antrean (*queue-based*), dan metrik evaluasi ASR. Tahap ini juga mencakup eksplorasi teori *human-computer interaction* untuk mendukung perancangan antarmuka koreksi yang ergonomis. Peneliti mengumpulkan berbagai referensi ilmiah untuk memastikan landasan teori yang digunakan telah sesuai dengan standar

akademik terkini.

2. **Perancangan Sistem:** Merancang skema interaksi antara *Next.js* sebagai orkestrator tugas dan *Python Worker* sebagai unit eksekusi GPU. Perancangan meliputi skema Redis *Pub/Sub* untuk pelaporan status transkripsi secara *real-time* serta struktur data laporan hasil benchmarking. Peneliti juga merancang diagram basis data untuk menyimpan informasi pengguna, berkas audio, dan segmen transkripsi.
3. **Implementasi Prototipe:** Membangun sistem transkripsi fungsional yang mengintegrasikan seluruh komponen perangkat lunak yang telah direncanakan. *Worker* dikonfigurasi menggunakan *Faster-Whisper* untuk memaksimalkan penggunaan VRAM pada RTX A5000 melalui teknik kuantisasi yang tepat. Implementasi ini mencakup pembuatan antarmuka web interaktif yang memungkinkan pengguna untuk mengunggah audio dan memantau progres secara langsung.
4. **Pengumpulan Data:** Menyiapkan 11.540 segmen audio dari korpus *Mozilla Common Voice* beserta berkas *source-of-truth* transkrip dalam format *TSV*. Data divalidasi kesesuaiannya antara durasi audio dan teks transkrip manual untuk menghindari bias saat proses evaluasi. Peneliti memastikan keragaman audio dalam hal kebisingan dan kecepatan bicara untuk menguji ketahanan model secara objektif.
5. **Eksekusi Benchmarking:** Menjalankan uji coba transkripsi secara berulang untuk varian model *tiny, base, small, medium, large-v2, large-v3,* dan *large-v3-turbo*. Data yang dicatat meliputi waktu inferensi (*Real Time Factor*), penggunaan memori maksimal, dan hasil teks transkripsi mentah. Setiap pengujian dilakukan dalam lingkungan yang terkontrol untuk meminimalisir pengaruh variabel eksternal terhadap hasil pengukuran.



Gambar 3.1: Alur Penelitian (*Flowchart*)

D. Data dan Sumber Data

Bahan penelitian utama berupa data audio dan transkrip referensi (*ground truth*).

1. **Dataset:** Menggunakan data dari korpus *Mozilla Common Voice* khusus kategori *Podcast*, yaitu *Podcast Homostoria* dan *Podcast Hari Minggoean* dalam Bahasa Indonesia. Rincian statistik dataset disajikan pada Tabel 3.1.
2. **Kriteria Audio:** Data terdiri dari rekaman percakapan alami (siniar) dengan total durasi mencakup 23,5 jam. Dataset ini dipilih karena memiliki tingkat kesulitan tinggi akibat variasi intonasi, logat lokal, dan gangguan latar belakang (*noise*).

3. **Transkrip Referensi:** Berkas *TSV* (*tab-separated values*) digunakan sebagai *source-of-truth* yang berisi teks transkrip manual yang telah divalidasi. Berkas ini berfungsi sebagai label acuan untuk menghitung tingkat kesalahan kata dan karakter.

Tabel 3.1: Statistik Dataset Penelitian

Nama Siniar	Jumlah Berkas	Jumlah Segmen	Total Durasi (Menit)
Homostoria	16	5.163	678,02
Hari Minggoean	42	6.377	735,43
Total	**58**	**11.540**	**1.413,45**

E. Alat dan Instrumen Penelitian

Instrumen penelitian terdiri dari perangkat keras dan perangkat lunak yang dipilih untuk mendukung arsitektur sistem terdistribusi berperforma tinggi. Pemilihan komponen ini didasarkan pada kebutuhan skalabilitas (*scalability*) dan efisiensi dalam menangani model AI yang berat.

1. **Perangkat Keras (Hardware):**
    - **Unit Pemrosesan AI:** NVIDIA RTX A5000 (24GB VRAM) via *Runpod* sebagai infrastruktur utama untuk tugas inferensi AI yang intensif.
    - **Server Aplikasi:** *Thin Client HP t630* dengan RAM 8GB sebagai server lokal untuk menjalankan web server *Next.js* dan *resource* lainnya yang dibutuhkan.
    - **Lingkungan Pengembangan:** Laptop *Lenovo IdeaPad Slim 3 14ALC6* dengan prosesor *AMD Ryzen 5 5500U*, RAM 20GB, dan penyimpanan *NVMe SSD* untuk proses koding, pengujian lokal, dan manajemen sistem.
2. **Perangkat Lunak (Software):**
    - **Framework Utama:** *Next.js* 16 dengan *React* 19 dan *TypeScript* untuk membangun sistem manajemen transkripsi yang modern dan *type-safe*.
    - **Backend & Database:** *Bun Runtime*, *PostgreSQL* sebagai basis data

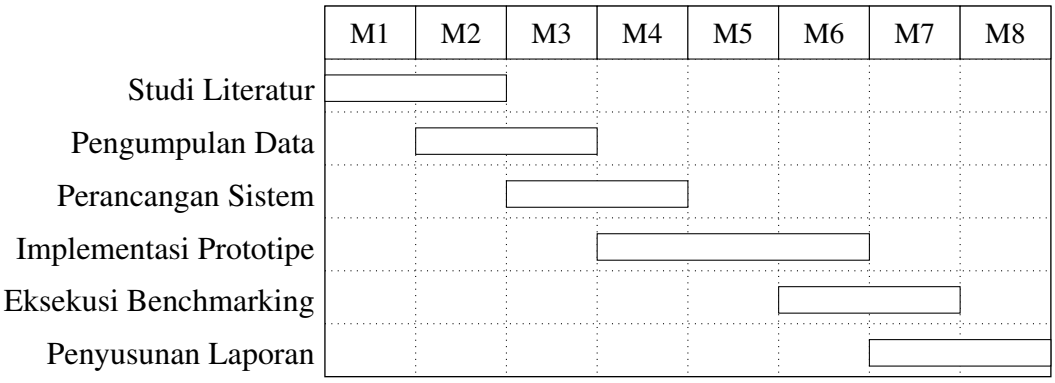
relasional, dan *Drizzle ORM* untuk manajemen skema data yang efisien.

- **Pemrosesan AI:** *Python* 3.10 dengan pustaka *WhisperX* dan *Faster-Whisper* yang telah dioptimasi menggunakan *CTranslate2*.
- **Antrean Tugas:** *Redis* dan *BullMQ* yang digunakan untuk mengelola antrean pekerjaan secara asinkron antara aplikasi web dan *worker* AI.
- **Penyimpanan Objek:** Layanan penyimpanan yang kompatibel dengan *S3* (*Garage*) untuk menyimpan berkas audio asli secara aman dan terstruktur.

F. Jadwal Penelitian

Penelitian direncanakan berlangsung selama delapan minggu. Rincian jadwal penelitian disajikan dalam bentuk *Gantt Chart* pada Tabel 3.1.

Tabel 3.2: Jadwal Penelitian (*Gantt Chart*)



BIBLIOGRAFI

Andreyev, A. (2025, March). *Quantization for OpenAI's Whisper Models: A Comparative Analysis.* arXiv. Diakses pada 2026-04-14http://arxiv.org/abs/2503.09905 (arXiv:2503.09905 [cs]) doi: 10.48550/arXiv.2503.09905

Bain, M., Huh, J., Han, T., & Zisserman, A. (2023, August). WhisperX: Time-Accurate Speech Transcription of Long-Form Audio. In *INTERSPEECH 2023* (pp. 4489–4493). ISCA. Diakses pada 2026-04-14https://www.isca-archive.org/interspeech_2023/bain23_interspeech.html doi: 10.21437/Interspeech.2023-78

Chen, X., Luo, K., Gee, T., & Nejati, M. (2024, February). *Does ChatGPT and Whisper Make Humanoid Robots More Relatable?* arXiv. Diakses pada 2026-04-14http://arxiv.org/abs/2402.07095 (arXiv:2402.07095 [cs]) doi: 10.48550/arXiv.2402.07095

Christodoulidou, P., Tanner, J., Stuart-Smith, J., McAuliffe, M., Murali, M., Smith, A., ... Kuschmann, A. (2025, August). A semi-automatic pipeline for transcribing and segmenting child speech. In *Interspeech 2025* (pp. 4278–4282). ISCA. Diakses pada 2026-04-14https://www.isca-archive.org/interspeech_2025/christodoulidou25_interspeech.html doi: 10.21437/Interspeech.2025-1030

Emmanni, P. S. (2021, February). The Role of TypeScript in Enhancing Development with Modern JavaScript Frameworks. *IJSR*, *10*(2), 1738–1741. Diakses pada 2026-04-14https://www.ijsr.net/getabstract.php?paperid=SR24401234212 doi: 10.21275/SR24401234212

Fathony, I. A. N., Mareta, A., Adiana, B. E., Wardhani, O., & Halim, A. (2025). Optimisasi Whisper Speech-to-Text Bahasa Indonesia dengan Hybrid Cloud dan Multi-Engine. , *18*(1).

Ferraro, A., Galli, A., La Gatta, V., & Postiglione, M. (2023, September). Benchmarking open source and paid services for speech to text: an analysis of quality and input variety. *Front. Big Data*, *6*, 1210559.

Diakses pada 2026-04-14https://www.frontiersin.org/articles/10.3389/fdata.2023.1210559/full doi: 10.3389/fdata.2023.1210559

Ferraz, T. P., Boito, M. Z., Brun, C., & Nikoulina, V. (2024, April). Multilingual DistilWhisper: Efficient Distillation of Multi-task Speech Models via Language-Specific Experts. In *ICASSP 2024 - 2024 IEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP)* (pp. 10716–10720). Diakses pada 2026-04-14http://arxiv.org/abs/2311.01070 (arXiv:2311.01070 [cs]) doi: 10.1109/ICASSP48485.2024.10447520

Graham, C., & Roll, N. (2024, February). Evaluating OpenAI's Whisper ASR: Performance analysis across diverse accents and speaker traits. *JASA Express Letters*, *4*(2), 025206. Diakses pada 2026-04-14https://pubs.aip.org/jel/article/4/2/025206/3267247/Evaluating-OpenAI-s-Whisper-ASR-Performance doi: 10.1121/10.0024876

Imai, S., Chowdhury, T., & Stent, A. J. (2025). Evaluating Open-Source ASR Systems: Performance Across Diverse Audio Conditions and Error Correction Methods.

Isyanto, H., Ibrahim, W., Samsinar, R., & Sudarwati, W. (2024). Accurate Speech Recognition AI using Model of Deep Learning for Security Access.

John, J. J., & Sharma, S. S. (2024). A Comparative Study of Agile and Waterfall Software Development Methodologies. *IJARSCT*, 54–57. Diambil darihttp://ijarsct.co.in/Paper15207.pdf doi: 10.48175/IJARSCT-15207

Latif, S., Zaidi, A., Cuayahuitl, H., Shamshad, F., Shoukat, M., Usama, M., & Qadir, J. (2025, June). *Transformers in Speech Processing: A Survey.* arXiv. Diakses pada 2026-04-14http://arxiv.org/abs/2303.11607 (arXiv:2303.11607 [cs]) doi: 10.48550/arXiv.2303.11607

Macháček, D., Dabre, R., & Bojar, O. (2023). Turning Whisper into Real-Time Transcription System. In *Proceedings of the 13th International Joint*

Conference on Natural Language Processing and the 3rd Conference of the Asia-Pacific Chapter of the Association for Computational Linguistics: System Demonstrations (pp. 17–24). Bali, Indonesia: Association for Computational Linguistics. Diakses pada 2026-04-14https://aclanthology.org/2023.ijcnlp-demo.3 doi: 10.18653/v1/2023.ijcnlp-demo.3

Nelson, J., & Gretkzi, M. (2023). Bridging the Gap Between Generalized ASR and Domain-Specific Communication Using Vosk-Driven Language Modeling.

Olev, A., & Alumäe, T. (2022). Estonian Speech Recognition and Transcription Editing Service. *BJMC*, *10*(3). Diakses pada 2026-04-14http://www.bjmc.lu.lv/fileadmin/user_upload/lu_portal/projekti/bjmc/Contents/10_3_14_Olev.pdf doi: 10.22364/bjmc.2022.10.3.14

Prabhavalkar, R., Hori, T., Sainath, T. N., Schlüter, R., & Watanabe, S. (2023, March). *End-to-End Speech Recognition: A Survey.* arXiv. Diakses pada 2026-04-14http://arxiv.org/abs/2303.03329 (arXiv:2303.03329 [eess]) doi: 10.48550/arXiv.2303.03329

Pratiwi, A. S., Wijoyo, S. H., & Wicaksono, S. A. (2022). Perancangan Antarmuka Pengguna Aplikasi Sistem Informasi Siswa berbasis Android menggunakan Metode User Centered Design (Studi pada : di SMK Telkom Banjarbaru).

Radford, A., Kim, J. W., Xu, T., Brockman, G., McLeavey, C., & Sutskever, I. (2022). Robust Speech Recognition via Large-Scale Weak Supervision.

Riebel, J. A. (2023). User-centered Design Methods in Data-Intensive Software Development Processes: A State-of-the-Art Review.

Teleki, M., Dong, X., Kim, S., & Caverlee, J. (2024, September). Comparing ASR Systems in the Context of Speech Disfluencies. In *Interspeech 2024* (pp. 4548–4552). ISCA. Diakses pada 2026-04-14https://www.isca-archive.org/interspeech_2024/teleki24_interspeech.html doi: 10.21437/Interspeech.2024-1270

Wang, S., Zhou, J., Zhao, S., & Qin, Y. (2025, June). *A Self-Training Approach for Whisper to Enhance Long Dysarthric Speech Recognition.* arXiv. Diakses

pada 2026-04-14http://arxiv.org/abs/2506.22810 (arXiv:2506.22810 [cs]) doi: 10.48550/arXiv.2506.22810