RANCANG BANGUN SISTEM SPEECH TO TEXT BERBASIS WEB MENGGUNAKAN MODEL OPENAI WHISPER

PROPOSAL PENELITIAN

UIN IMAM BONJOL
PADANG

Oleh:

MUHAMMAD IFFAN RAMADHAN

NIM. 2117020036

PROGRAM STUDI SISTEM INFORMASI
FAKULTAS SAINS DAN TEKNOLOGI
UNIVERSITAS ISLAM NEGERI IMAM BONJOL PADANG
PADANG
2026

HALAMAN PERSETUJUAN

Proposal penelitian dengan judul **"Rancang Bangun Sistem Speech To Text Berbasis Web Menggunakan Model OpenAI Whisper"** yang disusun oleh MUHAMMAD IFFAN RAMADHAN NIM 2117020036, telah diperiksa dan disetujui untuk diajukan dalam seminar proposal pada Program Studi Sistem Informasi Fakultas Sains dan Teknologi Universitas Islam Negeri Imam Bonjol Padang.

Padang, ... 2026

Menyetujui:

Pembimbing I	Pembimbing II
Ahmad Fauzi, M.T.I.	**Ozzy Secio Riza, M.Kom.**
NIP. 198805092018011001	NIP. 199310122019032015

KATA PENGANTAR

Puji syukur penulis panjatkan ke hadirat Allah SWT atas segala rahmat dan karunia-Nya sehingga proposal penelitian yang berjudul "Rancang Bangun Sistem Speech To Text Berbasis Web Menggunakan Model OpenAI Whisper" ini dapat diselesaikan. Shalawat serta salam semoga senantiasa tercurah kepada Nabi Muhammad SAW sebagai uswatun hasanah bagi umat manusia.

Proposal penelitian ini disusun sebagai salah satu syarat untuk melaksanakan penelitian skripsi pada Program Studi Sistem Informasi, Fakultas Sains dan Teknologi, Universitas Islam Negeri Imam Bonjol Padang. Penulis menyadari bahwa penyelesaian proposal ini tidak lepas dari bimbingan, dukungan, dan bantuan dari berbagai pihak. Oleh karena itu, penulis menyampaikan ucapan terima kasih kepada Bapak Ahmad Fauzi, M.T.I. selaku Pembimbing I dan Ibu Ozzy Secio Riza, M.Kom. selaku Pembimbing II yang telah memberikan arahan dan bimbingan yang sangat berharga.

Penulis menyadari bahwa proposal ini masih memiliki ruang untuk penyempurnaan. Oleh karena itu, kritik dan saran yang membangun sangat diharapkan demi perbaikan pelaksanaan penelitian ke depan. Semoga proposal penelitian ini dapat memberikan kontribusi nyata bagi pengembangan ilmu pengetahuan dan penerapan teknologi informasi.

Padang, ... 2026

Penulis

DAFTAR ISI

HALAMAN PERSETUJUAN ..... **ii**
KATA PENGANTAR ..... **iii**
DAFTAR ISI ..... **iv**
DAFTAR TABEL ..... **v**
DAFTAR GAMBAR ..... **vi**
BAB I PENDAHULUAN **1**
A Latar Belakang 1
B Rumusan Masalah 5
C Batasan Masalah 6
D Tujuan Penelitian 6
E Manfaat Penelitian 7
BAB II TINJAUAN PUSTAKA **8**
A Kerangka Teori 8
B Literatur Review 16
C Hipotesis Penelitian 21
BAB III METODE PENELITIAN **22**
A Jenis Penelitian 22
B Setting Penelitian 22
C Prosedur Penelitian 23
D Data dan Sumber Data 25
E Alat dan Instrumen Penelitian 25
F Teknik Analisis Data 26
G Jadwal Penelitian 28
DAFTAR PUSTAKA **30**

DAFTAR TABEL

2.1 Ringkasan Literatur Review 16

3.1 Statistik Dataset Penelitian 25

3.2 Jadwal Penelitian (*Gantt Chart*) 29

DAFTAR GAMBAR

3.1 Alur Penelitian (*Flowchart*)..... 24

BAB I
PENDAHULUAN

A. Latar Belakang

Pendokumentasian informasi dari rekaman audio, seperti rekaman siniar, wawancara penelitian, dan persidangan akademik, membutuhkan proses transkripsi teks sebagai langkah awal pengolahan data. Keberadaan teks transkripsi mempermudah pengindeksan, pencarian kata kunci, serta pengarsipan dokumen digital. Kendati demikian, proses transkripsi yang dilakukan secara manual membutuhkan alokasi waktu dan tenaga yang besar. Rata-rata seorang transkriptor profesional memerlukan waktu sekitar lima jam hanya untuk menyelesaikan satu jam rekaman audio dengan transkripsi verbatim yang akurat Christodoulidou dkk. (2025). Akibat tingginya beban kerja tersebut, banyak arsip audio pada berbagai lembaga pendidikan dan penelitian belum terdokumentasikan ke dalam bentuk teks tertulis Imai dkk. (2025).

Beban tersebut tidak hanya muncul pada tahap pengetikan, tetapi juga pada proses mendengarkan ulang, menentukan batas segmen, menyesuaikan tanda baca, dan memeriksa istilah yang tidak terdengar jelas. Pada rekaman percakapan, pekerjaan transkripsi menjadi lebih kompleks karena penutur dapat berbicara dengan kecepatan berbeda, menggunakan ungkapan tidak baku, atau menghasilkan ucapan yang saling bertumpuk. Dalam kondisi demikian, transkriptor harus berulang kali berpindah antara pemutar audio dan dokumen teks. Proses tersebut meningkatkan waktu penyelesaian dan membuka peluang terjadinya ketidakkonsistenan penulisan antarkalimat.

Pemanfaatan keluaran ASR sebagai draf dapat mengurangi sebagian pekerjaan tersebut, tetapi manfaatnya bergantung pada kualitas hasil pengenalan. Gaur dkk. menunjukkan bahwa keluaran ASR yang terlalu banyak kesalahan tidak selalu mempercepat transkripsi. Pada tingkat kesalahan tertentu, waktu yang dibutuhkan untuk memperbaiki hasil mesin dapat lebih panjang daripada menulis transkripsi dari awal. Temuan ini menunjukkan bahwa sistem transkripsi tidak cukup

hanya menghasilkan teks, tetapi juga perlu menyediakan informasi yang membantu pengguna menilai, menelusuri, dan memperbaiki kesalahan secara cepat Gaur dkk. (2016).

Perkembangan model *Automatic Speech Recognition* (ASR) modern berbasis arsitektur *Transformer*, seperti model OpenAI *Whisper*, memberikan peluang besar untuk mengotomatisasi konversi suara ke teks. Model ini dilatih menggunakan 680.000 jam data audio multibahasa sehingga memiliki ketahanan yang baik terhadap variasi aksen dan derau lingkungan Radford dkk. (2023). Namun, penerapan model ASR pada rekaman percakapan alami berbahasa Indonesia menghadapi tantangan tersendiri. Karakteristik percakapan spontan yang memuat variasi dialek daerah, alih kode (*code-switching*), bahasa percakapan non-formal, serta tumpang tindih suara antar-pembicara kerap menurunkan tingkat akurasi transkripsi otomatis. Oleh karena itu, hasil transkripsi ASR tidak dapat langsung diposisikan sebagai dokumen final, melainkan memerlukan proses verifikasi dan penyuntingan manual oleh manusia. Pendekatan *human-in-the-loop* (HITL) terbukti mampu menjaga integritas data teks sekaligus meningkatkan efisiensi waktu kerja secara signifikan, dengan syarat didukung oleh sistem antarmuka penyuntingan yang ergonomis dan tersinkronisasi Olev and Alumäe (2022).

Kinerja ASR juga dipengaruhi oleh karakteristik bahan uji. Sistem yang bekerja baik pada ucapan terarah belum tentu memberikan hasil yang sama pada siniar atau percakapan spontan. Imai dkk. mengevaluasi beberapa sistem ASR sumber terbuka pada kondisi audio yang beragam dan menunjukkan bahwa kebisingan, karakteristik penutur, serta tumpang tindih suara dapat memengaruhi nilai kesalahan transkripsi. Pada konteks siniar, Teleki dkk. juga menunjukkan bahwa pilihan sistem ASR perlu disesuaikan dengan jenis disfluensi yang terdapat dalam rekaman. Perbedaan antara pengulangan kata, interjeksi, dan bagian ucapan yang telah diedit dapat menghasilkan pola kesalahan yang berbeda. Karena itu, evaluasi sistem perlu menggunakan data percakapan yang mendekati kondisi penggunaan sebenarnya, bukan hanya data dengan artikulasi yang bersih Imai dkk. (2025); Teleki dkk. (2024).

Masalah lain terletak pada pengolahan audio berdurasi panjang. Model ASR umumnya memproses audio dalam segmen tertentu, sedangkan siniar yang digunakan dalam penelitian ini disimpan sebagai berkas utuh per episode. Pemotongan yang tidak tepat dapat memisahkan satu rangkaian ujaran, menghilangkan konteks di sekitar batas segmen, atau menghasilkan tanda waktu yang bergeser. WhisperX mengatasi sebagian persoalan tersebut melalui deteksi aktivitas suara, pemrosesan berkelompok, dan *forced alignment* pada tingkat kata. Pendekatan ini memperlihatkan bahwa akurasi transkripsi dan ketepatan waktu keluaran perlu dipertimbangkan secara bersamaan ketika sistem digunakan untuk menyunting rekaman panjang Bain, Huh, Han, and Zisserman (2023).

Dalam penggunaan berbahasa Indonesia, pemilihan model juga perlu mempertimbangkan keterbatasan sumber daya komputasi dan karakteristik bahasa. Model yang lebih besar cenderung membutuhkan memori dan waktu inferensi yang lebih tinggi, sedangkan model yang lebih kecil dapat menghasilkan kesalahan pada kata tidak baku, istilah khusus, atau bagian audio yang bising. Fathony dkk. menunjukkan bahwa optimasi dan penggunaan lebih dari satu mesin pemrosesan dapat dipertimbangkan untuk memperoleh keseimbangan antara akurasi dan efisiensi pada transkripsi bahasa Indonesia. Pertimbangan tersebut relevan bagi sistem yang ditujukan untuk digunakan secara mandiri, karena kapasitas perangkat keras dan biaya komputasi harus diperhitungkan sejak tahap perancangan Fathony dkk. (2025).

Tantangan berikutnya berkaitan dengan aspek infrastruktur dan tata kelola data. Pemanfaatan layanan ASR komputasi awan (*cloud*) komersial membutuhkan biaya langganan yang tinggi berdasarkan durasi audio, serta menimbulkan kekhawatiran terkait kerahasiaan dan privasi data penelitian institusi Ferraro dkk. (2023). Pengiriman berkas audio internal ke peladen (*server*) pihak ketiga di luar negeri berisiko melanggar ketentuan perlindungan data institusi lokal. Di sisi lain, pemanfaatan perangkat keras GPU mandiri (*self-hosted*) pada lingkungan lokal sering kali terkendala oleh manajemen beban komputasi model AI yang berat. Model inferensi ASR berbasis *Transformer* membutuhkan alokasi memori VRAM yang besar dan waktu eksekusi yang intensif. Tanpa pemisahan arsitektur yang terstruktur,

proses inferensi audio berdurasi panjang dapat menyebabkan kegagalan memori (*Out-of-Memory*) serta membekukan antarmuka aplikasi web Fathony dkk. (2025).

Perbandingan antara layanan komersial dan perangkat lunak sumber terbuka menunjukkan adanya pertukaran antara kualitas, biaya, kendali data, dan kemudahan pengelolaan. Layanan komersial biasanya menyediakan infrastruktur siap pakai, tetapi pengguna bergantung pada kebijakan penyedia, koneksi jaringan, serta mekanisme penagihan berdasarkan pemakaian. Sistem sumber terbuka memberi ruang untuk menjalankan model di lingkungan sendiri dan mengatur alur pemrosesan sesuai kebutuhan, tetapi membutuhkan pengelolaan perangkat keras, penyimpanan, antrean pekerjaan, dan pemantauan proses. Ferraro dkk. menekankan bahwa kualitas layanan ASR dapat berubah sesuai variasi masukan, sehingga penilaian sistem perlu mencakup kondisi audio yang nyata dan bukan hanya perbandingan angka akurasi pada satu jenis data Ferraro dkk. (2023).

Berdasarkan pertimbangan tersebut, sistem yang dibangun perlu memisahkan pekerjaan yang bersifat interaktif dari pekerjaan inferensi yang membutuhkan komputasi tinggi. Pengunggahan berkas, penampilan status, dan penyuntingan teks harus tetap responsif meskipun unit pemrosesan sedang menangani audio berdurasi panjang. Pemisahan ini juga memungkinkan pengujian beberapa varian model secara lebih teratur karena setiap pekerjaan dapat dicatat berdasarkan model, durasi audio, waktu inferensi, penggunaan VRAM, dan hasil transkripsinya. Dengan pencatatan tersebut, keputusan pemilihan model tidak hanya didasarkan pada ukuran parameter, tetapi juga pada kesesuaian antara akurasi, kecepatan, dan kebutuhan sumber daya.

Berdasarkan permasalahan tersebut, penelitian ini merancang dan membangun sebuah platform transkripsi audio mandiri bernama Skriptor. Sistem ini menerapkan arsitektur terdistribusi yang memisahkan antarmuka pengguna berbasis *Next.js* dengan unit pemrosesan inferensi berbasis *Python Worker*. Komunikasi asinkron dijembatani oleh sistem antrean tugas *Redis BullMQ*, sehingga proses inferensi model OpenAI *Whisper* dapat berjalan stabil di latar belakang tanpa menghambat responsivitas antarmuka web. Melalui integrasi ini, pengguna dapat memantau progres transkripsi secara langsung serta melakukan koreksi teks secara

interaktif melalui visualisasi gelombang audio. Dengan demikian, penelitian ini berfokus pada rancang bangun sistem *speech-to-text* berbasis *web* yang efisien dan terukur untuk alur kerja transkripsi audio percakapan bahasa Indonesia.

Selain menghasilkan teks, sistem ini dirancang untuk mendukung proses pemeriksaan oleh pengguna. Hasil transkripsi perlu disajikan bersama informasi waktu dan bagian audio yang terkait agar kesalahan dapat ditelusuri kembali ke sumbernya. Antarmuka yang demikian menempatkan model ASR sebagai alat bantu, sedangkan keputusan akhir mengenai ketepatan isi tetap berada pada pengguna. Pendekatan tersebut sesuai dengan karakteristik data percakapan yang sering memuat nama diri, istilah lokal, dan konteks yang tidak dapat ditentukan hanya dari sinyal suara.

Dengan mempertimbangkan kebutuhan tersebut, penelitian ini tidak hanya menguji kemampuan model dalam menghasilkan teks, tetapi juga mengukur efisiensi komputasi dan kegunaan antarmuka. Akurasi dinilai menggunakan WER dan CER, efisiensi dihitung melalui RTF serta penggunaan VRAM, sedangkan penerimaan antarmuka dievaluasi menggunakan SUS. Kombinasi pengukuran tersebut diharapkan memberikan gambaran yang lebih lengkap mengenai kelayakan sistem transkripsi mandiri untuk rekaman percakapan bahasa Indonesia.

B. Rumusan Masalah

Berdasarkan latar belakang di atas, rumusan masalah dalam penelitian ini dirumuskan sebagai berikut:

1. Bagaimana rancang bangun sistem *speech-to-text* berbasis *web* dengan arsitektur terdistribusi menggunakan *Next.js* dan *Python Worker*?
2. Bagaimana performa kecepatan (*inference time* dan *Real-Time Factor*), konsumsi VRAM, serta tingkat akurasi (*Word Error Rate* dan *Character Error Rate*) dari berbagai varian model OpenAI *Whisper* ketika diintegrasikan ke dalam arsitektur sistem terdistribusi tersebut?
3. Bagaimana tingkat kelayakan kegunaan (*usability*) antarmuka sistem *speech-to-text* berbasis *web* yang dikembangkan berdasarkan evaluasi *System Usability Scale* (SUS)?

C. Batasan Masalah

Penelitian ini dibatasi pada ruang lingkup sebagai berikut:

1. Model transkripsi yang diuji terbatas pada varian model OpenAI *Whisper* yang mencakup varian *Tiny, Base, Small, Medium, Large-v2, Large-v3,* dan *Large-v3-Turbo*.
2. Sistem dibangun menggunakan kerangka kerja *Next.js* 16 dengan bahasa *TypeScript* pada antarmuka web, serta unit *worker* berbasis *Python* yang terhubung melalui antrean terdistribusi berbasis *Redis BullMQ*.
3. Dataset pengujian menggunakan korpus percakapan bahasa Indonesia dari *Mozilla Data Collective* (MDC) yang terdiri dari 58 berkas audio utuh per episode siniar (*Homostoria* dan *Hari Minggoean*) dengan total durasi 23,5 jam, yang dievaluasi terhadap 11.540 segmen transkrip pada berkas acuan (*ground truth*) bertaraf TSV.
4. Infrastruktur inferensi pengujian performa dijalankan pada lingkungan komputasi berakselerasi GPU NVIDIA RTX A5000 (24GB VRAM) pada peladen *Runpod*.

D. Tujuan Penelitian

Tujuan yang hendak dicapai dalam penelitian ini adalah:

1. Merancang dan membangun sistem *speech-to-text* berbasis *web* dengan arsitektur terdistribusi yang memisahkan lapisan aplikasi (*Next.js*) dan lapisan komputasi kecerdasan buatan (*Python Worker*).
2. Mengevaluasi performa kecepatan inferensi, efisiensi konsumsi memori VRAM, dan tingkat akurasi transkripsi (WER dan CER) dari berbagai varian model OpenAI *Whisper* pada data rekaman percakapan bahasa Indonesia.
3. Mengukur tingkat kegunaan (*usability*) antarmuka sistem *speech-to-text* yang dikembangkan menggunakan instrumen kuesioner terstandarisasi *System Usability Scale* (SUS) terhadap 30 orang responden.

E. Manfaat Penelitian

Manfaat yang diharapkan dari hasil penelitian ini meliputi: Secara teoretis, penelitian ini memberikan data empiris dan analisis komparatif mengenai performa model ASR berbasis *Transformer* pada rekaman percakapan alami berbahasa Indonesia. Penelitian ini juga memperkaya kajian rekayasa perangkat lunak mengenai implementasi sistem AI terdistribusi dan penerapan prinsip *User-Centered Design* (UCD) pada antarmuka koreksi teks berbasis pendekatan *human-in-the-loop*.

Secara praktis, penelitian ini menghasilkan prototipe sistem transkripsi mandiri (*self-hosted*) bernama Skriptor yang dapat diterapkan oleh instansi akademis, lembaga riset, maupun profesional media. Sistem tersebut diharapkan membantu menurunkan biaya operasional transkripsi, menjaga kerahasiaan data audio lokal, dan mempercepat penyelesaian transkripsi melalui fasilitas penyuntingan yang terintegrasi.

BAB II
TINJAUAN PUSTAKA

A. Kerangka Teori

Bagian ini memaparkan teori-teori dasar yang menjadi landasan pengembangan dan analisis sistem transkripsi terdistribusi. Alur tinjauan dimulai dari konsep *Automatic Speech Recognition* (ASR) dan arsitektur model *Whisper* sebagai mesin transkripsi utama, dilanjutkan dengan karakteristik bahasa Indonesia yang menjadi konteks penelitian, kemudian *pipeline WhisperX* dan teknik optimasi inferensi yang digunakan, hingga metrik evaluasi, arsitektur sistem terdistribusi, aspek *usability*, dan pengujian perangkat lunak. Teori-teori ini menjadi dasar untuk merancang dan mengevaluasi sistem pada Bab 3.

1. Automatic Speech Recognition (ASR)

Automatic Speech Recognition (ASR) adalah teknologi yang memungkinkan komputer untuk mengubah sinyal suara menjadi teks secara otomatis. Proses ini melibatkan konversi gelombang akustik mentah menjadi representasi digital yang kemudian dipetakan ke dalam satuan bahasa (fonem, suku kata, atau kata). Secara tradisional, sistem ASR mengandalkan komponen terpisah seperti model akustik, model bahasa, dan leksikon pelafalan. Namun, perkembangan terkini telah bergeser ke arah model *End-to-End* (E2E) yang menyederhanakan alur kerja tersebut menjadi satu jaringan saraf tunggal yang melakukan pemetaan langsung dari audio ke teks Prabhavalkar dkk. (2023).

2. Arsitektur Model Whisper (OpenAI)

Model *Whisper* yang dikembangkan oleh OpenAI merupakan arsitektur jaringan saraf *End-to-End* (E2E) berbasis *Transformer Encoder-Decoder* yang dilatih menggunakan pendekatan *weakly supervised learning* pada skala data sebesar 680.000 jam audio multibahasa Radford dkk. (2023). Arsitektur ini terdiri dari tiga komponen utama: pra-pemrosesan audio, *encoder*, dan *decoder* autoregresif.

Pada tahap pra-pemrosesan audio (*Audio Pre-processing*), sinyal audio mentah (*raw audio*) diubah menjadi berfrekuensi tunggal (*monophonic*) dengan laju sampel (*sampling rate*) 16.000 Hz. Sinyal tersebut kemudian dipecah menjadi potongan (*chunks*) berdurasi 30 detik. Ekstraksi fitur dilakukan menggunakan transformasi Fourier jangka pendek (*Short-Time Fourier Transform* atau STFT) untuk menghasilkan spektrogram log-Mel berukuran 80 dimensi, atau 128 dimensi pada varian *Whisper v3*.

Encoder Transformer memetakan spektrogram masukan menjadi representasi fitur akustik. Dimensi waktu potongan audio terlebih dahulu direduksi melalui blok konvolusi dan dilengkapi *positional embeddings*. Representasi tersebut kemudian diproses oleh tumpukan blok *Transformer Encoder* yang terdiri atas mekanisme *Multi-Head Self-Attention* (MHA) dan jaringan *Feed-Forward* (FFN) dengan normalisasi lapisan *Pre-LN*.

Decoder Transformer berfungsi sebagai model bahasa kondisional (*conditional language model*) yang memprediksi urutan token secara autoregresif berdasarkan representasi akustik dari *encoder*. Mekanisme *masked Multi-Head Self-Attention* mencegah model melihat token berikutnya, sedangkan *Multi-Head Cross-Attention* menghubungkan *decoder* dengan representasi akustik *encoder*.

Selain itu, model *Whisper* mengintegrasikan beberapa tugas pemrosesan suara melalui token kontrol khusus (*special tokens*) pada awal urutan *decoder*. Token tersebut mencakup penanda awal transkripsi, bahasa sasaran seperti $\langle|\text{id}|\rangle$, jenis tugas berupa *transcribe* atau *translate*, serta token kontrol tanda waktu.

3. Karakteristik Bahasa Indonesia untuk ASR

Bahasa Indonesia memiliki tantangan tersendiri dalam ASR karena variasi dialek dan statusnya yang sering dikategorikan sebagai *low-resource language* dalam beberapa korpus besar. Meskipun Whisper memiliki performa multibahasa yang baik, akurasinya pada bahasa Indonesia sering kali lebih rendah dibandingkan bahasa Inggris, sehingga memerlukan evaluasi spesifik menggunakan *dataset* lokal Fathony dkk. (2025). Selain itu, percakapan alami berbahasa Indonesia, seperti pada

siniar, kerap mengandung bahasa gaul, ambiguitas linguistik, dan gangguan latar belakang yang menambah tingkat kesulitan transkripsi. Karakteristik ini menjadi dasar pemilihan korpus siniar berbahasa Indonesia sebagai objek pengujian dalam penelitian ini.

4. Inovasi *Pipeline* WhisperX

Meskipun *Whisper* memiliki kemampuan generalisasi yang sangat baik, model ini menghadapi keterbatasan serius ketika diterapkan pada audio berdurasi panjang, seperti masalah pergeseran tanda waktu (*timestamp drift*), halusinasi teks pada area hening (*hallucination loops*), dan latensi komputasi yang tinggi akibat sifat pemrosesan sekuensial autoregresif. Untuk mengatasi masalah tersebut, Bain , dkk. (2023) memperkenalkan *WhisperX*, sebuah kerangka kerja terpadu berkinerja tinggi yang menggabungkan deteksi aktivitas suara, inferensi berkelompok, dan penyelarasan fonem paksa.

Sebelum audio dikirim ke model ASR, *WhisperX* menerapkan *Voice Activity Detection* (VAD) dengan strategi *Cut & Merge*. VAD memisahkan segmen bicara aktif dari bagian hening, kemudian menggabungkan segmen aktif secara dinamis hingga panjang maksimal 30 detik. Dengan demikian, pemotongan berlangsung pada fase hening alami dan kecenderungan *Whisper* menghasilkan pengulangan frasa (*repetition loops*) dapat dikurangi.

Berbeda dari pemrosesan berurutan (*sequential decoding*) pada *Whisper* asli, *batched transcription* melalui *Faster-Whisper* memungkinkan paralelisasi komputasi pada GPU. Karena pembagian segmen berbasis VAD menghasilkan batas potongan yang bersih, setiap segmen dapat ditranskripsikan secara mandiri dan paralel dalam satu kelompok (*batch*). *WhisperX* mengintegrasikan *Faster-Whisper*, yaitu implementasi model *Whisper* dalam *C++* yang menggunakan pustaka optimasi *CTranslate2*. Kombinasi *batching* dan optimasi tersebut mempercepat waktu pemrosesan pada GPU NVIDIA modern.

Penanda waktu bawaan *Whisper* diprediksi pada tingkat frasa dengan presisi kasar dan rentan terhadap pergeseran temporal (*drifting*). Untuk memperoleh

penanda waktu tingkat kata (*word-level timestamp*) yang akurat, *WhisperX* menerapkan *forced alignment* menggunakan model berbasis *Connectionist Temporal Classification* (CTC), seperti *Wav2Vec 2.0* atau *WavLM*. Hasil pemetaan ini memberikan koordinat batas waktu awal dan akhir (t_{start}, t_{end}) setiap kata.

Tahap terakhir dalam *pipeline WhisperX* adalah *speaker diarization*, yaitu klasifikasi identitas suara untuk menentukan siapa yang berbicara pada setiap kata (*who spoke when*). Pustaka *PyAnnote Audio* mengekstraksi *speaker embeddings*, misalnya menggunakan *ECAPA-TDNN*, kemudian mengelompokkan pembicara dan memetakan identitasnya ke setiap kata berdasarkan koordinat waktu dari tahap *forced alignment*.

5. Optimasi Inferensi: Faster-Whisper dan Kuantisasi

Untuk menjalankan model besar pada lingkungan produksi yang efisien, diperlukan teknik optimasi inferensi yang mampu memangkas waktu pemrosesan dan konsumsi memori tanpa mendegradasi akurasi secara signifikan. Pustaka *CTranslate2* merupakan mesin inferensi berkinerja tinggi untuk model berarsitektur *Transformer*. Pustaka ini menerapkan peleburan operator (*operator fusion*), alokasi memori dinamis, serta paralelisasi CPU dan GPU untuk mengurangi *overhead* eksekusi *PyTorch*.

Kuantisasi model FP16 dan INT8 mengurangi presisi numerik bobot (*weights*) jaringan saraf. Pada inferensi FP32, setiap bobot membutuhkan 32 bit (4 bita), sedangkan INT8 merepresentasikannya dengan 8 bit (1 bita) melalui rumus:

$$W_q = \text{round}\left(\frac{W}{S} + Z\right) \tag{2.1}$$

di mana W melambangkan bobot berpresisi pecahan kontinu, S adalah faktor skala (*scale factor*), dan Z merupakan titik nol (*zero-point*). Kuantisasi ini menghemat kapasitas memori VRAM GPU hingga 50–75% serta mempercepat perpindahan data pada memori Andreyev (2025). Kecepatan inferensi diukur menggunakan *Real-Time Factor* (RTF), yaitu perbandingan waktu komputasi model ($\Delta t_{\text{inferensi}}$) terhadap durasi

berkas audio (Δt_{audio}):

$$\text{RTF} = \frac{\Delta t_{\text{inferensi}}}{\Delta t_{\text{audio}}} \tag{2.2}$$

Nilai RTF $< 1{,}0$ menandakan proses inferensi berjalan lebih cepat dibandingkan durasi pemutaran audio di dunia nyata (*faster than real-time*). Kebalikan dari RTF dinyatakan sebagai faktor percepatan komputasi (*Speed Multiplier*):

$$\text{Speed} = \frac{1}{\text{RTF}} = \frac{\Delta t_{\text{audio}}}{\Delta t_{\text{inferensi}}} \tag{2.3}$$

6. Metrik Evaluasi Akurasi: WER dan CER

Akurasi sistem ASR dievaluasi secara kuantitatif berdasarkan jarak suntingan Levenshtein (*Levenshtein Distance*) yang mengukur perbedaan jumlah operasi minimum antara urutan token keluaran hipotesis model dengan urutan token berkas acuan manual (*ground truth*). *Word Error Rate* (WER) merupakan metrik utama untuk mengukur tingkat kesalahan pengenalan wicara pada tingkat kata. Nilai WER dihitung melalui persamaan:

$$\text{WER} = \frac{S+D+I}{N} = \frac{S+D+I}{S+D+C} \tag{2.4}$$

di mana:

- S (*Substitutions*) adalah jumlah kata dalam referensi yang digantikan oleh kata lain pada keluaran model.
- D (*Deletions*) adalah jumlah kata dalam referensi yang hilang atau tidak dikenali oleh model.
- I (*Insertions*) adalah jumlah kata tambahan pada keluaran model yang sebenarnya tidak ada pada referensi.
- C (*Correct*) adalah jumlah kata yang berhasil dikenali secara tepat dan identik.
- N adalah total jumlah seluruh kata yang ada pada teks referensi acuan ($N = S+D+C$).

Character Error Rate (CER) merupakan metrik evaluasi kesalahan pada tingkat karakter yang dihitung dengan prinsip yang sama seperti WER:

$$\text{CER} = \frac{S_c + D_c + I_c}{N_c} \tag{2.5}$$

di mana S_c, D_c, I_c, dan N_c dihitung pada satuan karakter individual. CER sangat esensial dalam analisis bahasa Indonesia untuk mendeteksi ketepatan imbuhan (afiksasi) dan partikel yang mungkin hanya menimbulkan sedikit variasi karakter namun mengubah makna kata secara keseluruhan Ferraro dkk. (2023).

7. Arsitektur Sistem Terdistribusi

Sistem berskala besar yang menangani beban inferensi AI intensif memerlukan pemisahan tanggung jawab (*separation of concerns*) melalui arsitektur terdistribusi: Arsitektur *Message Queue Pattern* menempatkan peladen web sebagai produsen (*producer*) yang memasukkan pekerjaan ke dalam antrean terisolasi. Pustaka *BullMQ* berbasis *Redis* mengelola siklus hidup pekerjaan, mekanisme pengulangan saat gagal (*retry mechanism* dengan *exponential backoff*), serta penguncian tugas (*distributed locks*) untuk mencegah tabrakan eksekusi antar-pekerja.

Pada *Worker Pattern*, satu atau beberapa unit pekerja (*worker*) berjalan di lingkungan terpisah dan berfokus pada komputasi GPU. Pemisahan ini memungkinkan isolasi konkurensi, misalnya satu antrean untuk setiap GPU, sehingga penggunaan VRAM lebih stabil dan risiko galat kehabisan memori (*Out-of-Memory*) dapat dikurangi Macháček, Dabre, and Bojar (2023).

Progres inferensi disiarkan ke antarmuka klien melalui *Server-Sent Events* (SSE) yang dipicu oleh *Redis Pub/Sub*. Integritas data dari unit pemrosesan eksternal ke peladen web dijaga dengan verifikasi tanda tangan kriptografis menggunakan *Hash-based Message Authentication Code* (HMAC-SHA256).

8. Human-in-the-Loop (HITL), *Usability*, dan *System Usability Scale*

Konsep *Human-in-the-Loop* (HITL) mengakui bahwa sistem kecerdasan buatan, secanggih apa pun, tidak dapat sepenuhnya menggantikan penilaian manusia dalam tugas-tugas yang memerlukan pemahaman kontekstual dan ketelitian tinggi. Dalam konteks transkripsi, HITL menempatkan manusia sebagai validator akhir yang bertugas memeriksa dan mengoreksi hasil keluaran model ASR sebelum draf transkripsi dianggap final. Penelitian terdahulu menunjukkan bahwa alur kerja semi-otomatis yang menggabungkan draf transkripsi dari AI dengan antarmuka penyuntingan yang intuitif dapat meningkatkan produktivitas secara signifikan, terutama jika antarmuka tersebut dilengkapi dengan fitur visualisasi gelombang audio yang tersinkronisasi dengan teks (Olev dan Alumäe, 2022; Imai dkk., 2025). Namun, efektivitas pendekatan HITL sangat bergantung pada tingkat kegunaan (*usability*) antarmuka yang disediakan bagi pengguna.

Karena antarmuka koreksi menjadi titik temu utama antara manusia dan sistem, perancangannya perlu berpusat pada kebutuhan pengguna. Pendekatan *User-Centered Design* (UCD) menempatkan pengguna sebagai pusat proses desain, mulai dari pemahaman konteks penggunaan, perancangan solusi, hingga evaluasi Riebel (2023). Dalam penelitian ini, prinsip UCD diterapkan pada perancangan antarmuka koreksi Skriptor agar alur kerja penyuntingan hasil transkripsi dapat dilakukan secara intuitif dan efisien.

Menurut standar internasional ISO 9241-11, *usability* didefinisikan sebagai sejauh mana suatu produk dapat digunakan oleh pengguna tertentu untuk mencapai tujuan tertentu dengan efektivitas (*effectiveness*), efisiensi (*efficiency*), dan kepuasan (*satisfaction*) dalam konteks penggunaan tertentu. Untuk mengukur aspek *usability* secara kuantitatif pada sistem yang dikembangkan, diperlukan instrumen pengukuran yang terstandarisasi dan reliabel.

System Usability Scale (SUS) yang dikembangkan oleh Brooke (1996) merupakan kuesioner terstandarisasi yang terdiri dari 10 butir pernyataan dengan skala Likert 5 poin (1 = Sangat Tidak Setuju hingga 5 = Sangat Setuju). Kuesioner

ini dirancang untuk memberikan penilaian global terhadap kegunaan suatu sistem secara cepat dan murah. Sepuluh butir pernyataan SUS disusun secara bergantian antara pernyataan bernada positif (butir ganjil: 1, 3, 5, 7, 9) dan pernyataan bernada negatif (butir genap: 2, 4, 6, 8, 10). Prosedur perhitungan skor SUS adalah sebagai berikut:

1. Untuk setiap butir bernada positif (ganjil), kontribusi skor dihitung dengan mengurangi 1 dari respons pengguna: $(x_i - 1)$.
2. Untuk setiap butir bernada negatif (genap), kontribusi skor dihitung dengan mengurangi respons pengguna dari 5: $(5 - x_i)$.
3. Jumlahkan seluruh kontribusi skor dari 10 butir, lalu kalikan dengan 2,5 untuk mendapatkan skor akhir dalam rentang 0–100.

Secara matematis, rumus skor SUS dapat dituliskan sebagai:

$$\text{SUS} = 2{,}5 \times \left[\sum_{i \in \text{ganjil}} (x_i - 1) + \sum_{j \in \text{genap}} (5 - x_j) \right] \tag{2.6}$$

Berdasarkan studi empiris yang dilakukan oleh Bangor, Kortum, and Miller (2008) terhadap lebih dari 2.000 survei, interpretasi skor SUS dikategorikan ke dalam tiga tingkatan penerimaan: skor di atas 70 dikategorikan sebagai *Acceptable* (dapat diterima), skor antara 50–70 dikategorikan sebagai *Marginal* (perlu perbaikan), dan skor di bawah 50 dikategorikan sebagai *Not Acceptable* (tidak dapat diterima). Selain itu, Bangor , dkk. juga memetakan skor SUS ke dalam skala penilaian deskriptif (*adjective rating*): *Excellent* ($\geq$ 85,5), *Good* (72,6–85,5), *OK* (50,9–72,5), *Poor* (25,1–50,9), dan *Worst Imaginable* ($\leq$ 25,0).

9. Pengujian Perangkat Lunak

Pengujian perangkat lunak (*software testing*) merupakan proses evaluasi terhadap suatu sistem untuk memastikan bahwa perilaku dan kinerjanya telah sesuai dengan spesifikasi yang diharapkan serta terbebas dari kesalahan (*bugs* atau *errors*). Pengujian ini bertujuan untuk meningkatkan keandalan, keamanan, dan kualitas perangkat lunak secara keseluruhan sebelum dirilis ke lingkungan produksi.

Secara garis besar, pengujian perangkat lunak dibagi menjadi beberapa metode dan tingkatan, antara lain: *Black-box testing* mengevaluasi fungsionalitas sistem tanpa memerlukan pengetahuan mengenai struktur kode atau logika internalnya. Pengujian dilakukan dengan memberikan *input* tertentu dan memverifikasi kesesuaiannya dengan *output* yang diharapkan.

Unit testing menguji komponen perangkat lunak terkecil, seperti fungsi, kelas, atau modul, secara terisolasi. Sementara itu, *integration testing* memverifikasi interaksi dan aliran data di antara modul yang saling terhubung. Pengujian otomatis (*automated testing*) menjalankan skenario yang telah diprogram menggunakan perangkat lunak khusus. Pendekatan ini mempercepat verifikasi dan membantu mencegah regresi (*regression*) ketika kode diperbarui. Dalam penelitian ini, pengujian otomatis menggunakan *Vitest*.

B. Literatur Review

Tinjauan pustaka dilakukan dengan menganalisis berbagai penelitian terdahulu yang memiliki relevansi dengan pemrosesan bahasa alami dan arsitektur sistem terdistribusi. Data literatur tersebut dirangkum dalam Tabel 2.1 untuk memberikan gambaran komprehensif mengenai metode, tujuan, dan temuan utama dari setiap penelitian yang dirujuk.

Tabel 2.1: Ringkasan Literatur Review

Judul	**Penulis**	**Metode Penelitian**	**Tujuan Penelitian**	**Hasil Penelitian**
User-centered Design Methods in Data-Intensive Software...	Riebel dkk. (2023)	*Literature Review*	Menganalisis integrasi UCD dalam AI	UCD meningkatkan empati dan definisi masalah dalam pengembangan AI.
Berlanjut ke halaman berikutnya				

Tabel 2.1 – Lanjutan dari halaman sebelumnya

Judul	**Penulis**	**Metode Penelitian**	**Tujuan Penelitian**	**Hasil Penelitian**
Benchmarking open source and paid services for speech to text...	Ferraro dkk. (2023)	*Benchmark & WER Analysis*	Membandingkan performa layanan ASR berbayar dan open-source.	Layanan berbayar lebih akurat, namun performa sangat bergantung pada variasi input teks.
Evaluating Open-Source ASR Systems...	Imai dkk. (2025)	Evaluasi Eksperimental	Mengukur akurasi ASR pada audio bising	Perlu *robust error correction* untuk mengatasi bias demografis.
End-to-End Speech Recognition: A Survey	Prabhavalkar dkk. (2023)	*Survey* Literatur	Memetakan perkembangan E2E ASR	Model E2E mereduksi WER hingga 50% dibanding HMM tradisional.
Transformers in Speech Processing: A Survey	Latif dkk. (2025)	*Survey* Literatur	Menganalisis *Transformer* dalam audio	*Transformer* unggul dalam memodelkan dependensi jangka panjang.
Multilingual DistilWhisper...	Ferraz dkk. (2024)	Eksperimental (*Distillation*)	Meringankan model Whisper untuk bahasa langka	*DistilWhisper* meningkatkan performa bahasa *under-represented* dengan *overhead* minim.
Berlanjut ke halaman berikutnya				

Tabel 2.1 – Lanjutan dari halaman sebelumnya

Judul	**Penulis**	**Metode Penelitian**	**Tujuan Penelitian**	**Hasil Penelitian**
Does ChatGPT and Whisper Make Humanoid Robots More Relatable?	Chen dkk. (2024)	Evaluasi Pengguna	Membandingkan Whisper vs Google ASR pada robot	Whisper memiliki WER terendah (1.71%) dan paling disukai oleh pengguna.
Quantization for OpenAI's Whisper Models...	Andreyev (2025)	Analisis Komparatif	Mengukur dampak kuantisasi pada latensi	Kuantisasi INT8 mereduksi size 45% dan latensi 19% tanpa degradasi akurasi.
A Self-Training Approach for Whisper to Enhance Long Dysarthric Speech...	Wang dkk. (2025)	*Self-training method*	Meningkatkan ASR untuk penderita disartria	Metode *self-training* meningkatkan performa pada ucapan penderita disabilitas.
Accurate Speech Recognition AI using Model of Deep Learning...	Isyanto dkk. (2024)	Eksperimental CNN	Membangun ASR untuk keamanan perbankan	Algoritma CNN mencapai akurasi 99% untuk pengenalan kata kunci keamanan.
Evaluating OpenAI's Whisper ASR...	Graham and Roll (2024)	Analisis Performa	Mengevaluasi Whisper pada berbagai aksen	Whisper lebih akurat pada aksen asli (*native*) dibandingkan aksen *non-native*.

Berlanjut ke halaman berikutnya

Tabel 2.1 – Lanjutan dari halaman sebelumnya

Judul	**Penulis**	**Metode Penelitian**	**Tujuan Penelitian**	**Hasil Penelitian**
The Role of TypeScript in Enhancing Development...	Sekhar Emmann (2021)	*Empirical Analysis*	Menganalisis peran TypeScript dalam pengembangan aplikasi *web* modern.	TypeScript secara signifikan mengurangi kesalahan *runtime* dan meningkatkan skalabilitas.
A Comparative Study of Agile and Waterfall Software Development...	John dkk. (2024)	Analisis Komparatif	Membandingkan *Agile* vs *Waterfall*	*Agile* lebih unggul dalam kepuasan pelanggan dan kecepatan pengembangan.
Turning Whisper into Real-Time Transcription System	Macháček , dkk. (2023)	Implementasi	Mengembangkan sistem transkripsi *real-time* berbasis Whisper.	*Whisper-Streaming* mencapai latensi 3,3 detik dengan akurasi yang tetap terjaga.
WhisperX: Time-Accurate Speech Transcription...	Bain , dkk. (2023)	Pengembangan Sistem	Penyelarasan waktu tingkat kata pada Whisper	VAD dan *forced alignment* memungkinkan transkripsi 12x lebih cepat.
Berlanjut ke halaman berikutnya				

Tabel 2.1 – Lanjutan dari halaman sebelumnya

Judul	**Penulis**	**Metode Penelitian**	**Tujuan Penelitian**	**Hasil Penelitian**
Bridging the Gap Between Generalized ASR and Domain-Specific...	Nelson dkk. (2025)	Integrasi Vosk	Menyesuaikan ASR untuk domain spesifik	Language modeling pada Vosk efektif untuk istilah medis dan hukum.
A semi-automatic pipeline for transcribing child speech	Christodoulidou, dkk. (2025)	Evaluasi *Pipeline*	Membangun *pipeline* transkripsi suara anak	Koreksi manual sebelum *forced alignment* meningkatkan kualitas data akustik.
Comparing ASR Systems in Context of Speech Disfluencies	Teleki dkk. (2024)	Analisis Korpus Besar	Mengevaluasi Google ASR vs Whisper	Whisper lebih unggul dalam menangani interjeksi dan keraguan bicara.
Perancangan Antarmuka Pengguna Aplikasi Informasi Siswa...	Pratiwi dkk. (2022)	*User Centered Design* (UCD)	Merancang aplikasi informasi sekolah	Metode UCD menghasilkan desain yang 100% dapat digunakan oleh target *user*.
Estonian Speech Recognition and Transcription Editing Service	Olev and Alumäe (2022)	Pengembangan Layanan	Membangun sistem transkripsi berbasis wav2vec2.0	Sistem berbasis E2E mencapai WER 6.9% dan mendukung *editing* kolaboratif.

Berdasarkan tinjauan literatur di atas, penelitian ini memadukan tiga pilar

utama yang saling terkait. Pilar pertama adalah mesin inferensi transkripsi berupa model OpenAI *Whisper* yang dioptimasi menggunakan pustaka *Faster-Whisper* (CTranslate2) dan *pipeline WhisperX* untuk menangani berkas audio berdurasi panjang secara efisien. Pilar kedua adalah fondasi arsitektur terdistribusi berbasis *Next.js* dan *Python Worker* yang dihubungkan melalui antrean tugas asinkron *Redis BullMQ* untuk memastikan stabilitas operasional mandiri (*self-hosted*) pada infrastruktur lokal. Pilar ketiga adalah perancangan antarmuka penyuntingan terintegrasi dengan pendekatan *User-Centered Design* (UCD) yang dievaluasi menggunakan instrumen *System Usability Scale* (SUS). Ketiga pilar ini menjadi kerangka acuan utama perancangan sistem Skriptor yang dibahas pada Bab III.

C. Hipotesis Penelitian

Berdasarkan landasan teori dan tinjauan pustaka yang telah diuraikan, hipotesis yang diajukan dalam penelitian ini adalah:

1. Arsitektur terdistribusi yang memisahkan peladen web (*Next.js*) dan unit inferensi (*Python Worker*) melalui antrean terisolasi *Redis BullMQ* mampu menjaga stabilitas respons antarmuka pengguna serta mencegah terjadinya kegagalan memori (*Out-of-Memory*) saat memproses transkripsi audio berdurasi panjang secara asinkron.
2. Peningkatan kapasitas parameter model OpenAI *Whisper* (dari varian *Tiny* hingga *Large-v3*) berbanding lurus dengan peningkatan akurasi transkripsi (penurunan nilai WER dan CER), namun berbanding terbalik terhadap kecepatan komputasi (peningkatan nilai RTF) dan kebutuhan alokasi memori VRAM GPU.
3. Evaluasi kegunaan antarmuka sistem Skriptor berbasis pendekatan *User-Centered Design* (UCD) memperoleh skor rata-rata *System Usability Scale* (SUS) ≥ 70 (kategori *Acceptable* dengan tingkat kelayakan *Good*), sehingga dinyatakan layak dan efektif untuk mendukung alur kerja transkripsi audio percakapan bahasa Indonesia.

BAB III
METODE PENELITIAN

A. Jenis Penelitian

Penelitian ini termasuk dalam kategori penelitian rekayasa perangkat lunak dengan pendekatan *Research and Development* (R&D). Pengembangan sistem mengikuti model *waterfall* yang berjalan secara sekuensial melalui tahap perancangan, implementasi, dan pengujian, dengan penekanan iteratif khusus pada fase perancangan antarmuka. Antarmuka koreksi pada sistem dirancang menggunakan pendekatan *User-Centered Design* (UCD), yaitu dimulai dari pemahaman kebutuhan pengguna, perancangan *wireframe*, hingga validasi desain sebelum implementasi. Pengujian sistem mencakup tiga aspek. Pertama, pengujian fungsionalitas sistem melalui *black-box testing* manual serta *unit testing* otomatis menggunakan *Vitest* untuk memastikan kode berjalan andal. Kedua, pengujian teknis berupa *benchmarking* yang mengukur kecepatan inferensi, konsumsi VRAM, dan akurasi transkripsi (WER dan CER) dari berbagai varian model OpenAI *Whisper*. Ketiga, pengujian non-teknis berupa evaluasi kegunaan (*usability*) menggunakan kuesioner *System Usability Scale* (SUS).

B. Setting Penelitian

Penelitian ini berlangsung dengan memanfaatkan infrastruktur *cloud* dan perangkat keras lokal. Tugas inferensi model AI yang intensif dijalankan pada *remote pod* dari layanan *Runpod* yang menyediakan GPU NVIDIA RTX A5000 dengan VRAM 24GB. Sementara itu, aplikasi web beserta layanan pendukungnya berjalan pada server lokal. Pemilihan infrastruktur ini didasari kebutuhan akan lingkungan komputasi yang terkontrol dan fleksibel, sehingga spesifikasi perangkat keras dapat disesuaikan dengan kebutuhan model kecerdasan buatan skala besar. Penelitian direncanakan berlangsung selama delapan bulan, dimulai pada bulan Maret hingga Oktober 2026.

C. Prosedur Penelitian

Prosedur penelitian disusun secara sistematis agar setiap tahap menghasilkan luaran yang dapat divalidasi pada tahap berikutnya. Rincian setiap tahapan dijelaskan sebagai berikut: Tahap studi literatur diawali dengan meninjau dokumentasi model *Whisper*, arsitektur sistem terdistribusi berbasis antrean (*queue-based*), serta metrik evaluasi ASR. Teori *human-computer interaction* juga dikaji untuk mendukung perancangan antarmuka koreksi yang ergonomis. Referensi ilmiah yang relevan dikumpulkan sebagai dasar penelitian.

Pada tahap perancangan sistem, disusun skema interaksi antara *Next.js* sebagai orkestrator tugas dan *Python Worker* sebagai unit eksekusi GPU. Perancangan mencakup Redis *Pub/Sub* untuk pelaporan status secara *real-time*, struktur data laporan *benchmarking*, serta diagram basis data. Antarmuka koreksi dirancang menggunakan pendekatan *User-Centered Design* (UCD), dimulai dari identifikasi kebutuhan calon pengguna hingga penyusunan dan validasi *wireframe* serta *prototype*.

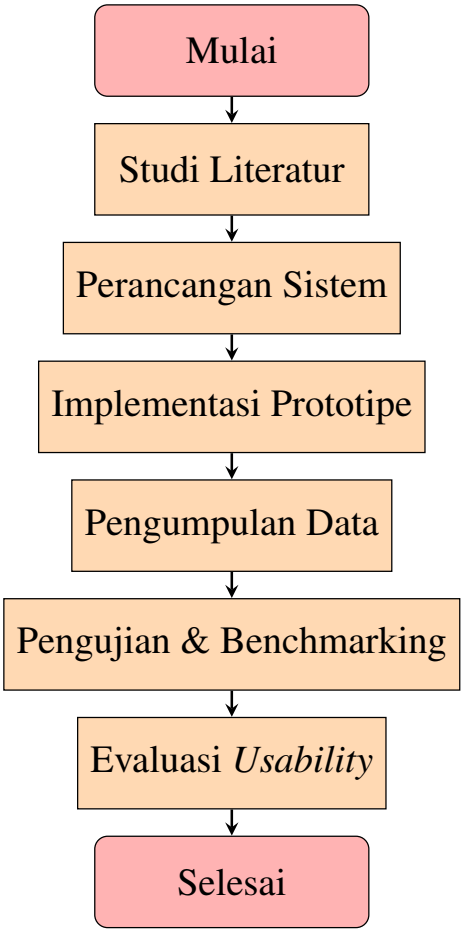
Implementasi prototipe dilakukan dengan mengintegrasikan komponen yang telah dirancang. *Worker* dikonfigurasi menggunakan *pipeline WhisperX* yang menggabungkan *Faster-Whisper*, VAD, dan *forced alignment*. Teknik kuantisasi diterapkan untuk mengoptimalkan VRAM pada RTX A5000. Implementasi juga mencakup antarmuka web untuk mengunggah audio dan memantau progres.

Pada tahap pengumpulan data, sebanyak 58 berkas audio utuh per episode disiapkan dari korpus *Mozilla Data Collective* (MDC), yang terdiri atas 16 episode *Homostoria* dan 42 episode *Hari Minggoean*. Berkas acuan *ground truth* berformat *TSV* memuat 11.540 segmen transkrip beserta anotasi waktu. Kesesuaian durasi audio dan teks manual divalidasi sebelum evaluasi.

Pengujian sistem dilakukan melalui *black-box testing* manual dan pengujian unit menggunakan *Vitest*. Skenario pengujian mencakup pengunggahan audio, penolakan format yang tidak didukung, pemantauan progres, dan penyimpanan hasil koreksi. Setelah sistem stabil, transkripsi diuji pada varian *tiny, base, small,*

medium, large-v2, large-v3, dan *large-v3-turbo*. Waktu inferensi, RTF, penggunaan memori, dan hasil transkripsi mentah dicatat dalam lingkungan terkontrol.

Evaluasi *usability* dilakukan menggunakan kuesioner *System Usability Scale* (SUS) terhadap 30 responden yang mewakili mahasiswa, akademisi, dan pembuat konten digital. Responden dipilih secara *purposive sampling*, kemudian diminta menjalankan tugas mengunggah audio, memantau progres, dan mengoreksi transkripsi pada antarmuka Skriptor. Setelah menyelesaikan tugas, responden mengisi sepuluh pernyataan SUS berskala Likert 5 poin. Skor yang diperoleh dihitung dan diinterpretasikan berdasarkan kategori standar Bangor , dkk. (2008); Brooke (1996).



Gambar 3.1: Alur Penelitian (*Flowchart*)

D. Data dan Sumber Data

Bahan penelitian utama berupa data audio dan transkrip referensi (*ground truth*). Data penelitian menggunakan korpus *Mozilla Data Collective* (MDC) yang terdiri atas 16 episode *Homostoria* dan 42 episode *Hari Minggoean* dalam bahasa Indonesia. Dengan demikian, data berjumlah 58 berkas audio utuh per episode. Rekaman tersebut merupakan percakapan alami dengan total durasi 23,5 jam dan memiliki variasi intonasi, logat lokal, serta gangguan latar belakang (*noise*).

Berkas *TSV* (*tab-separated values*) digunakan sebagai *ground truth*. Berkas ini memuat 11.540 segmen transkrip manual beserta anotasi waktu dan berfungsi sebagai acuan untuk menghitung kesalahan pada tingkat kata maupun karakter. Rincian statistik dataset disajikan pada Tabel 3.1.

Tabel 3.1: Statistik Dataset Penelitian

Nama Siniar	**Jumlah Berkas**	**Jumlah Segmen**	**Total Durasi (Menit)**
Homostoria	16	5.163	678,02
Hari Minggoean	42	6.377	735,43
Total	**58**	**11.540**	**1.413,45**

E. Alat dan Instrumen Penelitian

Instrumen penelitian terdiri dari perangkat keras dan perangkat lunak yang dipilih untuk mendukung arsitektur sistem terdistribusi berperforma tinggi. Pemilihan komponen ini didasarkan pada kebutuhan skalabilitas (*scalability*) dan efisiensi dalam menangani model AI yang berat. Perangkat keras penelitian meliputi NVIDIA RTX A5000 dengan VRAM 24 GB melalui *Runpod* untuk inferensi AI, *Thin Client HP t630* dengan RAM 8 GB sebagai server aplikasi lokal, serta laptop *Lenovo IdeaPad Slim 3 14ALC6* dengan prosesor *AMD Ryzen 5 5500U*, RAM 20 GB, dan penyimpanan *NVMe SSD* untuk pengembangan serta pengujian lokal.

Perangkat lunak yang digunakan meliputi *Visual Studio Code*, *Git*, dan *Bun Runtime*. Lapisan aplikasi dibangun dengan *TypeScript*, *Next.js* 16, *React* 19, *Tailwind CSS* v4, *shadcn/ui*, dan *Drizzle ORM*. Infrastruktur data menggunakan *PostgreSQL*, *Redis* dengan *BullMQ*, serta *Garage S3*. Pemrosesan audio menggunakan *PyTorch*, *WhisperX*, *Faster-Whisper*, *CTranslate2*, *pyannote.audio*

3.1, dan *jiwer*, sedangkan pengujian unit dilakukan dengan *Vitest*.

Instrumen evaluasi yang digunakan adalah kuesioner *System Usability Scale* (SUS), yang terdiri atas sepuluh pernyataan berskala Likert 5 poin Brooke (1996). Kuesioner dibagikan setelah responden menyelesaikan skenario tugas pada antarmuka Skriptor. Responden berjumlah 30 orang dan dipilih secara *purposive sampling* dari kelompok mahasiswa, akademisi, serta pembuat konten digital yang memiliki kebutuhan transkripsi.

F. Teknik Analisis Data

Analisis data dalam penelitian ini dilakukan melalui lima pendekatan yang saling melengkapi guna mengevaluasi aspek akurasi, efisiensi, kegunaan, dan fungsionalitas sistem secara komprehensif.

1. Pra-pemrosesan dan Normalisasi Teks

Sebelum dilakukan perbandingan antara teks hipotesis (keluaran ASR) dan teks referensi (*ground truth*), kedua teks terlebih dahulu melewati tahap normalisasi. Proses normalisasi meliputi pengubahan seluruh karakter ke huruf kecil (*case-folding*), penghapusan tanda baca menggunakan ekspresi reguler, dan penyeragaman spasi. Secara formal, fungsi normalisasi didefinisikan sebagai berikut:

$$f(\text{teks}) = \text{lowercase}(\text{strip}(\text{remove_punctuation}(\text{teks}))) \tag{3.1}$$

Teks yang telah dinormalisasi kemudian digunakan sebagai masukan untuk penghitungan metrik akurasi.

2. Analisis Akurasi ASR (WER dan CER)

Akurasi transkripsi diukur menggunakan dua metrik utama yang berbasis jarak *Levenshtein*. *Word Error Rate* (WER) mengukur tingkat kesalahan pada level kata dengan persamaan:

$$\text{WER} = \frac{S+D+I}{N} = \frac{S+D+I}{S+D+C} \tag{3.2}$$

dengan S = jumlah substitusi, D = jumlah penghapusan (*deletions*), I = jumlah penyisipan (*insertions*), C = jumlah kata benar (*correct*), dan N = total kata pada teks referensi. *Character Error Rate* (CER) mengukur tingkat kesalahan pada level karakter menggunakan jarak *Levenshtein*:

$$\text{CER} = \frac{S_c + D_c + I_c}{N_c} \tag{3.3}$$

dengan S_c, D_c, dan I_c berturut-turut adalah jumlah substitusi, penghapusan, dan penyisipan karakter, sedangkan N_c adalah jumlah karakter pada teks referensi. Perhitungan WER dan CER dilakukan menggunakan pustaka *jiwer* pada *Python*. Nilai yang lebih rendah menunjukkan akurasi transkripsi yang lebih baik.

3. Analisis Efisiensi Komputasi

Efisiensi komputasi diukur melalui *Real-Time Factor* (RTF) dan penggunaan VRAM puncak. RTF merupakan rasio antara waktu inferensi dan durasi audio yang diproses:

$$\text{RTF} = \frac{\Delta t_{\text{inferensi}}}{\Delta t_{\text{audio}}} \tag{3.4}$$

Nilai RTF < 1 menunjukkan bahwa sistem memproses audio lebih cepat dari waktu nyata. Kecepatan pemrosesan juga dapat dinyatakan sebagai *Speed Factor* (Speed $= 1/\text{RTF}$). Penggunaan VRAM puncak (*Peak VRAM*) dicatat melalui *polling* perintah `nvidia-smi` atau fungsi `torch.cuda.memory_reserved()` pada *PyTorch*. Data tersebut digunakan untuk menentukan kelayakan model pada berbagai spesifikasi GPU.

4. Analisis Kegunaan (*Usability*) dengan SUS

Evaluasi kegunaan antarmuka dilakukan menggunakan kuesioner *System Usability Scale* (SUS) yang terdiri dari 10 butir pernyataan berskala Likert 1–5 Brooke (1996). Kuesioner didistribusikan kepada 30 responden. Skor SUS untuk

setiap responden dihitung dengan formula:

$$\text{SUS} = 2{,}5 \times \left[\sum_{i \in \text{ganjil}} (x_i - 1) + \sum_{j \in \text{genap}} (5 - x_j) \right] \tag{3.5}$$

dengan x_i adalah skor butir ganjil (pernyataan positif) dan x_j adalah skor butir genap (pernyataan negatif). Rentang skor SUS adalah 0–100. Rata-rata dan standar deviasi skor SUS kemudian dihitung dan diinterpretasikan berdasarkan skala penerimaan (*Acceptability Ranges*), skala huruf (*Grade Scale*), dan peringkat kata sifat (*Adjective Rating*) dari Bangor , dkk. (2008).

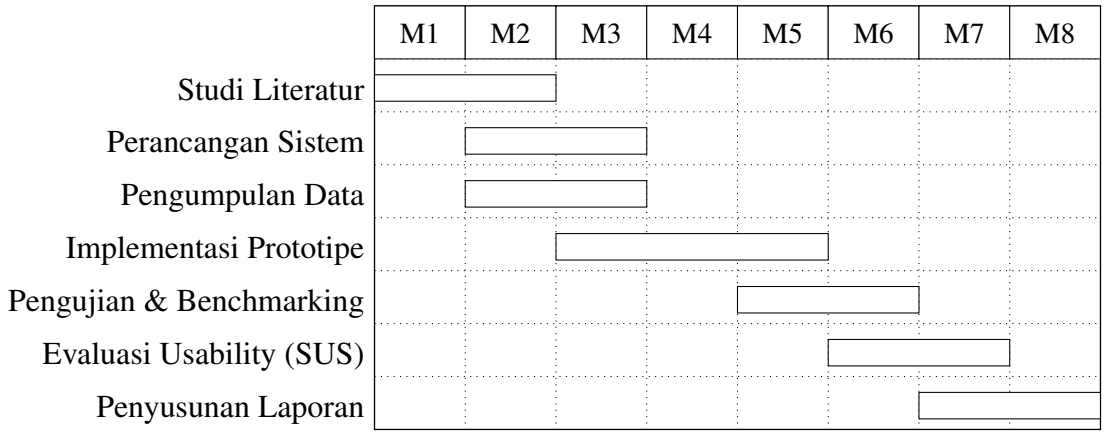
5. Analisis Pengujian Fungsional

Pengujian fungsional dilakukan melalui pendekatan kotak hitam manual (*manual black-box testing*). Setiap fitur utama sistem diuji berdasarkan matriks skenario pengujian yang memuat: identifikasi skenario, kondisi masukan (*input*), langkah pengujian, respons sistem yang diharapkan (*expected result*), dan hasil pengamatan aktual (*actual result*). Setiap skenario dinilai dengan status "Berhasil" atau "Gagal" berdasarkan kesesuaian antara keluaran aktual dan keluaran yang diharapkan.

G. Jadwal Penelitian

Penelitian direncanakan berlangsung selama delapan bulan. Rincian jadwal penelitian disajikan dalam bentuk *Gantt Chart* pada Tabel 3.2.

Tabel 3.2: Jadwal Penelitian (*Gantt Chart*)



DAFTAR PUSTAKA

Andreyev, A. (2025, March). *Quantization for OpenAI's Whisper Models: A Comparative Analysis.* arXiv. Diakses pada 2026-04-14http://arxiv.org/abs/2503.09905 (arXiv:2503.09905 [cs]) doi: 10.48550/arXiv.2503.09905

Bain, M., Huh, J., Han, T., & Zisserman, A. (2023, August). WhisperX: Time-Accurate Speech Transcription of Long-Form Audio. In *INTERSPEECH 2023* (pp. 4489–4493). ISCA. Diakses pada 2026-04-14https://www.isca-archive.org/interspeech_2023/bain23_interspeech.html doi: 10.21437/Interspeech.2023-78

Bangor, A., Kortum, P. T., & Miller, J. T. (2008, July). An Empirical Evaluation of the System Usability Scale. *International Journal of Human–Computer Interaction*, *24*(6), 574–594. Diakses pada 2026-05-23https://www.tandfonline.com/doi/full/10.1080/10447310802205776 doi: 10.1080/10447310802205776

Brooke, J. (1996). SUS - A quick and dirty usability scale..

Chen, X., Luo, K., Gee, T., & Nejati, M. (2024, February). *Does ChatGPT and Whisper Make Humanoid Robots More Relatable?* arXiv. Diakses pada 2026-04-14http://arxiv.org/abs/2402.07095 (arXiv:2402.07095 [cs]) doi: 10.48550/arXiv.2402.07095

Christodoulidou, P., Tanner, J., Stuart-Smith, J., McAuliffe, M., Murali, M., Smith, A., … Kuschmann, A. (2025, August). A semi-automatic pipeline for transcribing and segmenting child speech. In *Interspeech 2025* (pp. 4278–4282). ISCA. Diakses pada 2026-04-14https://www.isca-archive.org/interspeech_2025/christodoulidou25_interspeech.html doi: 10.21437/Interspeech.2025-1030

Fathony, I. A. N., Mareta, A., Adiana, B. E., Wardhani, O., & Halim, A. (2025). Optimisasi Whisper Speech-to-Text Bahasa Indonesia dengan Hybrid Cloud dan Multi-Engine. *ELKOM (Jurnal Elektronika dan Komputer)*, *18*(1).

Ferraro, A., Galli, A., La Gatta, V., & Postiglione, M. (2023, September). Benchmarking open source and paid services for speech to text: an analysis of quality and input variety. *Front. Big Data*, *6*, 1210559. Diakses pada 2026-04-14https://www.frontiersin.org/articles/10.3389/fdata.2023.1210559/full doi: 10.3389/fdata.2023.1210559

Ferraz, T. P., Boito, M. Z., Brun, C., & Nikoulina, V. (2024, April). Multilingual DistilWhisper: Efficient Distillation of Multi-task Speech Models via Language-Specific Experts. In *ICASSP 2024 - 2024 IEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP)* (pp. 10716–10720). Diakses pada 2026-04-14http://arxiv.org/abs/2311.01070 (arXiv:2311.01070 [cs]) doi: 10.1109/ICASSP48485.2024.10447520

Gaur, Y., Lasecki, W. S., Metze, F., & Bigham, J. P. (2016, April). The effects of automatic speech recognition quality on human transcription latency. In *Proceedings of the 13th International Web for All Conference* (pp. 1–8). Montreal Canada: ACM. Diakses pada 2026-04-14https://dl.acm.org/

doi/10.1145/2899475.2899478 doi: 10.1145/2899475.2899478

Graham, C., & Roll, N. (2024, February). Evaluating OpenAI's Whisper ASR: Performance analysis across diverse accents and speaker traits. *JASA Express Letters*, *4*(2), 025206. Diakses pada 2026-04-14https://pubs.aip.org/jel/article/4/2/025206/3267247/Evaluating-OpenAI-s-Whisper-ASR-Performance doi: 10.1121/10.0024876

Imai, S., Chowdhury, T., & Stent, A. J. (2025). Evaluating Open-Source ASR Systems: Performance Across Diverse Audio Conditions and Error Correction Methods. , 5027–5039.

Isyanto, H., Ibrahim, W., Samsinar, R., & Sudarwati, W. (2024). Accurate Speech Recognition AI using Model of Deep Learning for Security Access.

John, J. J., & Sharma, S. S. (2024, January). A Comparative Study of Agile and Waterfall Software Development Methodologies. *IJARSCT*, 54–57. Diakses pada 2026-04-14http://ijarsct.co.in/Paper15207.pdf doi: 10.48175/IJARSCT-15207

Latif, S., Zaidi, A., Cuayahuitl, H., Shamshad, F., Shoukat, M., Usama, M., & Qadir, J. (2025, June). *Transformers in Speech Processing: A Survey.* arXiv. Diakses pada 2026-04-14http://arxiv.org/abs/2303.11607 (arXiv:2303.11607 [cs]) doi: 10.48550/arXiv.2303.11607

Macháček, D., Dabre, R., & Bojar, O. (2023). Turning Whisper into Real-Time Transcription System. In *Proceedings of the 13th International Joint Conference on Natural Language Processing and the 3rd Conference of the Asia-Pacific Chapter of the Association for Computational Linguistics: System Demonstrations* (pp. 17–24). Bali, Indonesia: Association for Computational Linguistics. Diakses pada 2026-04-14https://aclanthology.org/2023.ijcnlp-demo.3 doi: 10.18653/v1/2023.ijcnlp-demo.3

Nelson, J., & Gretkzi, M. (2025). Bridging the Gap Between Generalized ASR and Domain-Specific Communication Using Vosk-Driven Language Modeling. *ResearchGate Preprint*.

Olev, A., & Alumäe, T. (2022). Estonian Speech Recognition and Transcription Editing Service. *BJMC*, *10*(3). Diakses pada 2026-04-14http://www.bjmc.lu.lv/fileadmin/user_upload/lu_portal/projekti/bjmc/Contents/10_3_14_Olev.pdf doi: 10.22364/bjmc.2022.10.3.14

Prabhavalkar, R., Hori, T., Sainath, T. N., Schlüter, R., & Watanabe, S. (2023, March). *End-to-End Speech Recognition: A Survey.* arXiv. Diakses pada 2026-04-14http://arxiv.org/abs/2303.03329 (arXiv:2303.03329 [eess]) doi: 10.48550/arXiv.2303.03329

Pratiwi, A. S., Wijoyo, S. H., & Wicaksono, S. A. (2022). Perancangan Antarmuka Pengguna Aplikasi Sistem Informasi Siswa berbasis Android menggunakan Metode User Centered Design (Studi pada : di SMK Telkom Banjarbaru). *Jurnal Pengembangan Teknologi Informasi dan Ilmu Komputer (J-PTIIK)*, *6*(9), 4554–4561.

Radford, A., Kim, J. W., Xu, T., Brockman, G., McLeavey, C., & Sutskever, I. (2023). Robust Speech Recognition via Large-Scale Weak Supervision. , *202*.

Riebel, J. A. (2023). User-centered Design Methods in Data-Intensive Software Development Processes: A State-of-the-Art Review. *State-of-the-Art Review in Data-Intensive Software Development Processes*.

Sekhar Emmanni, P. (2021, February). The Role of TypeScript in Enhancing Development with Modern JavaScript Frameworks. *IJSR*, *10*(2), 1738–1741. Diakses pada 2026-04-14https://www.ijsr.net/getabstract.php?paperid=SR24401234212 doi: 10.21275/SR24401234212

Teleki, M., Dong, X., Kim, S., & Caverlee, J. (2024, September). Comparing ASR Systems in the Context of Speech Disfluencies. In *Interspeech 2024* (pp. 4548–4552). ISCA. Diakses pada 2026-04-14https://www.isca-archive.org/interspeech_2024/teleki24_interspeech.html doi: 10.21437/Interspeech.2024-1270

Wang, S., Zhou, J., Zhao, S., & Qin, Y. (2025, June). *A Self-Training Approach for Whisper to Enhance Long Dysarthric Speech Recognition.* arXiv. Diakses pada 2026-04-14http://arxiv.org/abs/2506.22810 (arXiv:2506.22810 [cs]) doi: 10.48550/arXiv.2506.22810