PROPOSAL PENELITIAN

ANALISIS PERFORMA DAN AKURASI MODEL WHISPER PADA SISTEM TRANSKRIPSI TERDISTRIBUSI MENGGUNAKAN NEXT.JS DAN PYTHON WORKER

UIN IMAM BONJOL
PADANG

Oleh:

MUHAMAD IFFAN RAMADHAN

NIM. 2117020036

PROGRAM STUDI SISTEM INFORMASI
FAKULTAS SAINS DAN TEKNOLOGI
UNIVERSITAS ISLAM NEGERI IMAM BONJOL PADANG

2026

PROPOSAL PENELITIAN

ANALISIS PERFORMA DAN AKURASI MODEL WHISPER PADA SISTEM TRANSKRIPSI TERDISTRIBUSI MENGGUNAKAN NEXT.JS DAN PYTHON WORKER

Diajukan Sebagai Salah Satu Syarat untuk Meraih Gelar Sarjana (S1)

UIN IMAM BONJOL
PADANG

Oleh:

MUHAMAD IFFAN RAMADHAN
NIM. 2117020036

PROGRAM STUDI SISTEM INFORMASI
FAKULTAS SAINS DAN TEKNOLOGI
UNIVERSITAS ISLAM NEGERI IMAM BONJOL PADANG

2026

HALAMAN PERSETUJUAN

Proposal penelitian dengan judul **"Analisis Performa dan Akurasi Model Whisper pada Sistem Transkripsi Terdistribusi Menggunakan Next.js dan Python Worker"** yang disusun oleh MUHAMAD IFFAN RAMADHANNIM 2117020036, telah diperiksa dan disetujui untuk diajukan dalam seminar proposal pada Program Studi Sistem InformasiFakultas Sains dan TeknologiUniversitas Islam Negeri Imam Bonjol Padang.

Padang, ... 2026

Menyetujui:

Pembimbing I	Pembimbing II
Ahmad Fauzi, M.T.I	**Ozzy Secio Riza, M.Kom**
NIP. 123456789	NIP. 987654321

DAFTAR ISI

DAFTAR ISI . . . . . **iv**

DAFTAR TABEL . . . . . **v**

DAFTAR GAMBAR . . . . . **vi**

BAB I PENDAHULUAN **1**

A Latar Belakang 1

B Rumusan Masalah 2

C Batasan Masalah 2

D Tujuan Penelitian 2

E Manfaat Penelitian 3

BAB II TINJAUAN PUSTAKA **4**

A Kerangka Teori 4

B Literatur Review 5

C Hipotesis 6

BAB III METODE PENELITIAN **7**

A Jenis Penelitian 7

B Setting Penelitian 7

C Bahan atau Materi Penelitian 7

D Alat/Instrumen Penelitian 7

E Teknik Pengumpulan Data/Prosedur Penelitian 8

F Teknik Analisis Data 8

DAFTAR PUSTAKA **9**

DAFTAR TABEL

1.1 Contoh Tabel Perbandingan 3

DAFTAR GAMBAR

1.1 Logo Universitas (Contoh Gambar) 3

BAB I
PENDAHULUAN

A. Latar Belakang

Perkembangan teknologi kecerdasan buatan, khususnya dalam bidang *Automatic Speech Recognition* (ASR), telah mengubah cara interaksi manusia dengan data suara. Kebutuhan akan transkripsi otomatis semakin meningkat di berbagai sektor, termasuk lingkungan akademis untuk keperluan dokumentasi rapat, perkuliahan, dan wawancara penelitian. Saat ini, solusi transkripsi berbasis *cloud* seperti Google *Cloud Speech-to-Text* menjadi pilihan utama karena akurasinya yang tinggi. Namun, penggunaan layanan tersebut memerlukan biaya operasional yang signifikan dan menimbulkan kekhawatiran terkait kedaulatan serta privasi data sensitif yang diunggah ke peladen pihak ketiga.

Di sisi lain, model *state-of-the-art* seperti *Whisper* yang diperkenalkan oleh OpenAI (Radford dkk., n.d.) menawarkan performa yang kompetitif dan bersifat *open source*. Hal ini membuka peluang bagi institusi pendidikan untuk mengimplementasikan sistem transkripsi mandiri (*self-hosted*). Mayoritas kampus dan laboratorium penelitian saat ini telah memiliki infrastruktur perangkat keras berupa komputer dengan *Graphic Processing Unit* (GPU) yang mumpuni. Dengan memanfaatkan sumber daya komputasi internal tersebut, biaya operasional dapat ditekan secara drastis dibandingkan menggunakan API komersial (Fathony, Mareta, Adiana, Wardhani, & Halim, n.d.).

Namun, implementasi *Whisper* pada lingkungan produksi berskala *Software-as-a-Service* (SaaS) menghadapi tantangan teknis dalam hal manajemen antrean dan skalabilitas. Diperlukan arsitektur sistem terdistribusi yang efisien untuk menangani beban kerja transkripsi yang intensif secara komputasi. Selain itu, terdapat berbagai varian model *Whisper* mulai dari *Tiny* hingga *Large-v3-Turbo* yang memiliki karakteristik performa dan akurasi yang berbeda-beda. Oleh karena itu, penelitian ini bertujuan untuk melakukan analisis mendalam mengenai performa dan akurasi berbagai varian model *Whisper* pada sistem transkripsi terdistribusi yang

dibangun menggunakan *Next.js* dan *Python Worker*.

B. Rumusan Masalah

Berdasarkan latar belakang di atas, rumusan masalah dalam penelitian ini adalah:

1. Bagaimana performa kecepatan (*inference time*) dan efisiensi penggunaan sumber daya (VRAM) antar varian model *Whisper* pada sistem terdistribusi?
2. Sejauh mana tingkat akurasi (*Word Error Rate*) yang dihasilkan oleh berbagai varian model *Whisper* pada sampel audio rekaman lokal bahasa Indonesia?
3. Bagaimana efektivitas arsitektur terdistribusi menggunakan *Next.js* dan *Python Worker* dalam menangani beban kerja transkripsi otomatis?

C. Batasan Masalah

Penelitian ini dibatasi pada hal-hal sebagai berikut:

1. Model yang diuji terbatas pada varian *Whisper* (*Tiny, Small, Medium, Large-v3, Large-v3-Turbo*).
2. Sistem dibangun menggunakan *Next.js* untuk *frontend/backend* utama dan *Python* untuk *worker* pemrosesan audio.
3. Pengujian akurasi menggunakan 5 sampel audio rekaman lokal dari berbagai sumber (seperti YouTube) dalam bahasa Indonesia.
4. Infrastruktur pengujian menggunakan *remote pod/container* dari *Runpod* dengan spesifikasi NVIDIA RTX A4000.

D. Tujuan Penelitian

Tujuan dari penelitian ini adalah:

1. Menganalisis perbandingan performa kecepatan dan konsumsi sumber daya dari seluruh varian model *Whisper*.
2. Mengukur tingkat akurasi transkripsi model *Whisper* pada data audio lokal bahasa Indonesia untuk menentukan model yang paling optimal antara akurasi dan kecepatan.
3. Mengimplementasikan prototipe sistem transkripsi terdistribusi yang dapat memanfaatkan *resource* GPU internal secara efisien.

E. Manfaat Penelitian

Tabel 1.1: Contoh Tabel Perbandingan

Varian	Akurasi	Kecepatan
Tiny	85%	10x
Small	90%	5x



Gambar 1.1: Logo Universitas (Contoh Gambar)

Manfaat yang diharapkan dari penelitian ini adalah:

1. **Manfaat Teoritis:** Memberikan kontribusi berupa data pembanding (*benchmarking*) terbaru mengenai performa varian model *Whisper* pada bahasa Indonesia dalam lingkungan sistem terdistribusi.
2. **Manfaat Praktis:** Memberikan solusi sistem transkripsi yang ekonomis dan aman bagi institusi yang memiliki sumber daya GPU, serta mengurangi ketergantungan pada layanan *cloud* berbayar.

BAB II
TINJAUAN PUSTAKA

A. Kerangka Teori

Bagian ini memaparkan teori-teori dasar yang menjadi landasan dalam pengembangan dan analisis sistem transkripsi terdistribusi.

A.1. Automatic Speech Recognition (ASR) dan Model Whisper

Automatic Speech Recognition (ASR) adalah teknologi yang memungkinkan komputer untuk mengubah sinyal suara menjadi teks secara otomatis. Perkembangan terbaru dalam bidang ini didominasi oleh pendekatan *deep learning*, salah satunya adalah model *Whisper* yang dikembangkan oleh OpenAI. *Whisper* menggunakan arsitektur *Transformer* berbasis *encoder-decoder* yang dilatih menggunakan 680.000 jam data audio multibahasa secara *weakly supervised* (Radford dkk., n.d.). Hal ini membuat model tersebut memiliki tingkat ketahanan (*robustness*) yang tinggi terhadap aksen, kebisingan latar belakang, dan istilah teknis dibandingkan model ASR tradisional.

A.2. Sistem Transkripsi Terdistribusi

Sistem terdistribusi adalah sekumpulan komputer mandiri yang tampak bagi pengguna sebagai satu sistem tunggal yang koheren. Dalam konteks transkripsi otomatis, beban kerja pemrosesan audio bersifat *compute-intensive*. Oleh karena itu, penggunaan arsitektur terdistribusi yang memisahkan antara antarmuka pengguna (*Next.js*) dan unit pemrosesan (*Python Worker*) sangat krusial. Komunikasi antar komponen ini biasanya dilakukan melalui *Message Broker* seperti Redis atau RabbitMQ untuk mengelola antrean tugas secara asinkron.

A.3. Metrik Evaluasi: Word Error Rate (WER)

Akurasi sistem ASR diukur menggunakan metrik *Word Error Rate* (WER). WER dihitung dengan menjumlahkan jumlah substitusi (S), penghapusan (D), dan

penyisipan (I) kata, kemudian dibagi dengan jumlah total kata (N) pada referensi asli:

$$WER = \frac{S + D + I}{N} \tag{II.1}$$

Nilai WER yang lebih rendah menunjukkan tingkat akurasi yang lebih tinggi.

B. Literatur Review

Penelitian mengenai implementasi dan optimasi model *Whisper* telah banyak dilakukan dalam beberapa tahun terakhir. Fathony dkk. (Fathony dkk., n.d.) melakukan penelitian mengenai optimasi *Whisper* untuk Bahasa Indonesia menggunakan pendekatan *Hybrid Cloud*. Temuan mereka menunjukkan bahwa penggunaan strategi *multi-engine* dapat meningkatkan kecepatan transkripsi secara signifikan tanpa mengorbankan akurasi secara drastis pada data bahasa lokal.

Penelitian lain oleh Andreyev (Andreyev, 2025) berfokus pada teknik kuantisasi model *Whisper* (INT4, INT5, dan INT8) untuk mengurangi latensi dan penggunaan memori pada perangkat *edge*. Hasilnya menunjukkan bahwa kuantisasi mampu mengurangi penggunaan memori hingga 45% dengan penurunan akurasi yang minimal. Hal ini relevan dengan penelitian ini yang juga mempertimbangkan penggunaan sumber daya GPU yang terbatas di lingkungan kampus.

Bain dkk. (Bain, Huh, Han, & Zisserman, 2023) memperkenalkan *WhisperX* yang mengoptimalkan model *Whisper* asli dengan menambahkan fitur *Voice Activity Detection* (VAD) dan *forced alignment* untuk menghasilkan *timestamp* tingkat kata yang lebih akurat. Meskipun penelitian ini berfokus pada model *Whisper* standar, teknik pemrosesan yang diusulkan dalam *WhisperX* menjadi referensi penting dalam memahami efisiensi pemrosesan audio berdurasi panjang.

Perbedaan utama penelitian ini dengan penelitian sebelumnya adalah pada fokus implementasi sistem transkripsi yang terintegrasi secara penuh dalam ekosistem SaaS terdistribusi menggunakan *Next.js* dan *Python Worker*, serta melakukan *benchmarking* komprehensif pada seluruh varian model *Whisper* menggunakan data rekaman lokal bahasa Indonesia guna mencari titik temu antara efisiensi biaya infrastruktur dan akurasi hasil.

C. Hipotesis

Berdasarkan tinjauan pustaka di atas, diajukan hipotesis sebagai berikut:

1. Terdapat korelasi positif antara ukuran model *Whisper* dengan tingkat akurasi, di mana model *Large-v3* diharapkan menghasilkan WER terendah namun dengan *inference time* paling lama.
2. Model *Large-v3-Turbo* mampu memberikan akurasi yang mendekati model *Large-v3* dengan kecepatan pemrosesan yang jauh lebih efisien pada infrastruktur NVIDIA RTX A4000.
3. Arsitektur terdistribusi menggunakan *Python Worker* mampu menjaga stabilitas sistem transkripsi pada beban kerja tinggi dibandingkan dengan pemrosesan monolitik.

BAB III
METODE PENELITIAN

A. Jenis Penelitian

Penelitian ini dikategorikan sebagai penelitian eksperimental teknis dengan fokus pada pengujian performa (*benchmarking*) dan pengembangan sistem (*Research and Development*). Peneliti melakukan eksperimen langsung terhadap berbagai varian model *Whisper* untuk mengukur metrik akurasi dan kecepatan dalam lingkungan sistem terdistribusi.

B. Setting Penelitian

Penelitian ini dilakukan secara daring melalui pemanfaatan infrastruktur *cloud* dan perangkat keras lokal.

1. **Lokasi:** Pengujian dilakukan menggunakan *remote pod* dari layanan *Runpod* untuk mendapatkan lingkungan komputasi GPU yang terkontrol.
2. **Waktu:** Penelitian direncanakan berlangsung selama tiga bulan, mencakup tahap pengembangan sistem, pengumpulan data audio lokal, hingga tahap analisis hasil *benchmarking*.

C. Bahan atau Materi Penelitian

Bahan penelitian utama berupa data audio yang akan ditranskripsi.

1. **Dataset:** Menggunakan 5 sampel audio rekaman lokal dalam Bahasa Indonesia yang diambil dari sumber terbuka (seperti YouTube atau arsip rekaman rapat publik).
2. **Kriteria Audio:** Audio dipilih dengan durasi yang bervariasi (antara 5 hingga 15 menit) dengan tingkat kejelasan suara yang berbeda untuk menguji ketangguhan model.

D. Alat/Instrumen Penelitian

Instrumen penelitian terdiri dari perangkat keras dan perangkat lunak sebagai berikut:

1. **Perangkat Keras (Hardware):**
    - NVIDIA RTX A4000 (16GB VRAM) via *Runpod*.

- Apple Mac Mini M4 sebagai unit pembanding efisiensi komputasi lokal.

2. **Perangkat Lunak (Software):**
    - Sistem Operasi: Ubuntu 22.04 LTS (pada *Runpod*).
    - Framework Utama: *Next.js* (React) dan *Node.js*.
    - Pemrosesan Audio: *Python* 3.10 dengan pustaka *Faster-Whisper* atau *OpenAI Whisper*.
    - Manajemen Antrean: Redis dan *BullMQ*.

E. Teknik Pengumpulan Data/Prosedur Penelitian

Prosedur penelitian dilakukan melalui tahapan-tahapan berikut:

1. **Perancangan Arsitektur:** Membangun skema komunikasi antara *Web Server* (Next.js) dan *GPU Worker* (Python) menggunakan Redis sebagai *Message Broker*.
2. **Persiapan Dataset:** Mengunduh dan melakukan *preprocessing* pada 5 sampel audio lokal (konversi format ke 16kHz mono WAV).
3. **Eksekusi Transkripsi:** Menjalankan proses transkripsi untuk setiap sampel audio menggunakan seluruh varian model *Whisper* (*Tiny, Small, Medium, Large-v3, Large-v3-Turbo*).
4. **Pencatatan Metrik:** Mencatat waktu mulai dan selesai (*inference time*), serta penggunaan VRAM maksimal selama proses berlangsung.

F. Teknik Analisis Data

Data yang terkumpul dianalisis secara kuantitatif melalui:

1. **Analisis Akurasi:** Menghitung nilai *Word Error Rate* (WER) dengan membandingkan teks hasil transkripsi otomatis terhadap teks referensi (transkripsi manual).
2. **Analisis Performa:** Membandingkan kecepatan pemrosesan (*Real Time Factor* atau detik per menit audio) antar model.
3. **Analisis Efisiensi:** Mengevaluasi model mana yang memberikan rasio terbaik antara akurasi (WER terendah) dan biaya komputasi (VRAM/Waktu).

BIBLIOGRAFI

Andreyev, A. (2025, March). *Quantization for OpenAI's Whisper Models: A Comparative Analysis.* arXiv. Diakses pada 2026-04-14http://arxiv.org/abs/2503.09905 (arXiv:2503.09905 [cs]) doi: 10.48550/arXiv.2503.09905

Bain, M., Huh, J., Han, T., & Zisserman, A. (2023, August). WhisperX: Time-Accurate Speech Transcription of Long-Form Audio. In *INTERSPEECH 2023* (pp. 4489–4493). ISCA. Diakses pada 2026-04-14https://www.isca-archive.org/interspeech_2023/bain23_interspeech.html doi: 10.21437/Interspeech.2023-78

Fathony, I. A. N., Mareta, A., Adiana, B. E., Wardhani, O., & Halim, A. (n.d.). Optimisasi Whisper Speech-to-Text Bahasa Indonesia dengan Hybrid Cloud dan Multi-Engine. , *18*(1).

Radford, A., Kim, J. W., Xu, T., Brockman, G., McLeavey, C., & Sutskever, I. (n.d.). Robust Speech Recognition via Large-Scale Weak Supervision.